

بسم الله الرحمن الرحيم



دانشگاه شهید باهنر کرمان

دانشکده فنی و مهندسی
بخش مهندسی کامپیوتر

پایان نامه تحصیلی برای دریافت درجه کارشناسی ارشد
رشته مهندسی کامپیوتر گرایش هوش مصنوعی

تشخیص قدرتمند بدافزارهای اندروید با استفاده از شبکه‌های عصبی
ترنسفورمر

مؤلف:

علیرضا ایرانمنش

استاد راهنما:

دکتر حمید میروزی

اردیبهشت ۱۴۰۴

به نام خدا

منشور اخلاق پژوهش

با استعانت از خدای سبحان و اعتقاد راسخ به این که عالم محضر خداست و او بواره ناغیر بر اعمال ماست و به منظور انجام شایسته‌ی پژوهش‌های اصلی، تولید دانش جدید و بهسازی زندگی‌های بشر، ما دانشجویان و اعضای هیأت علمی دانشگاه پژوهشگاه‌های کشور:

- ☐ تمام تلاش خود را برای کشف حقیقت و حفظ حقیقت به کار خواهیم بست و از هر گونه جعل و تحریف و فعالیت‌های علمی پرهیزی کنیم.
- ☐ حقوق پژوهشگران، پژوهیدگان (انسان، حیوان، نبات و اشیا)، سازمان‌های صاحبان حق را بر رعایت می‌شناسیم و در حفظ آن‌ها می‌کوشیم.
- ☐ به مالکیت‌های و ممنوعی آثار پژوهشی ارجح می‌نیم، برای انجام پژوهشی اصیل اهتمام و هزینه‌ها را از سرعت علمی و ارجاع نامناسب اجتناب می‌کنیم.
- ☐ ضمن پابندی به انصاف و اجتناب از هر گونه تبعیض و تعصب در کیه فعالیت‌های پژوهشی، رهیافتی اتخاذ نخواهیم کرد.
- ☐ ضمن امانت‌داری، از منابع و امکانات اقتصادی، انسانی و فنی موجود، استفاده بهر دور را خواهیم کرد.
- ☐ از انتشار غیر اخلاقی نتایج پژوهش، نظیر انتشار موازی، بهوشان و چندگانه‌نگاری پرهیزی کنیم.
- ☐ اصل همراه بودن و رازداری را محور تمام فعالیت‌های پژوهشی خود قرار می‌دهیم.
- ☐ در بهر فعالیت‌های پژوهشی به منافع ملی توجه کرده و برای تحقق آن می‌کوشیم.
- ☐ خویش را ملزم به رعایت کلیه بندهای علمی رسته‌شده توسط قوانین و مقررات، سیاست‌های حرفه‌ای، سازمانی، دولتی و راهبردی ملی و بهر مراحل پژوهش می‌دانیم.
- ☐ رعایت اصول اخلاق در پژوهش را اقدامی فرهنگی می‌دانیم و به منظور بالندگی این فرهنگ، به ترویج و اشاعه آن در جامعه اهتمام می‌ورزیم.



دانشگاه شهید باهنر کرمان

تعهدنامه

اینجانب علیرضا ایرانمنش به شماره دانشجویی ۴۰۱۱۵۵۰۱۵ دانشجوی مقطع کارشناسی ارشد رشته مهندسی کامپیوتر-هوش مصنوعی دانشکده فنی مهندسی دانشگاه شهید باهنر کرمان نویسنده پایان‌نامه با عنوان «تشخیص قدرتمند بدافزارهای اندروید با استفاده از شبکه‌های عصبی ترنسفورمر» تحت راهنمایی دکتر حمید میروزی تأیید می‌کنم که این پایان‌نامه نتیجه پژوهش اینجانب می‌باشد و در عین حال که موضوع آن تکراری نیست، در صورت استفاده از منابع دیگران، نشانی دقیق و مشخصات کامل آن درج شده است. همچنین موارد زیر را نیز تعهد می‌کنم:

- ۱- برای انتشار تمام یا قسمتی از داده‌ها یا دستاوردهای خود در مجامع و رسانه‌های علمی اعم از همایش‌ها و مجلات داخلی و خارجی به صورت مقاله، کتاب، ثبت اختراع و به صورت مکتوب یا غیرمکتوب، با کسب مجوز از دانشگاه شهید باهنر کرمان و استاد(ان) راهنما اقدام نمایم.
- ۲- از درج اسامی افراد خارج از کمیته پایان‌نامه در جمع نویسندگان مقاله‌های مستخرج از پایان‌نامه، بدون مجوز استاد(ان) راهنما اجتناب نمایم و اسامی افراد کمیته پایان‌نامه را در جمع نویسندگان مقاله درج نمایم.
- ۳- از درج نشانی یا وابستگی کاری (affiliation) نویسندگان سازمان‌های دیگر (غیر از دانشگاه شهید باهنر کرمان) در مقاله‌های مستخرج از پایان‌نامه بدون تأیید استاد(ان) راهنما اجتناب نمایم^۱.
- ۴- کلیه ضوابط و اصول اخلاقی مربوط به استفاده از موجودات زنده یا بافتهای آنها را برای انجام پایان‌نامه رعایت نمایم.
- ۵- در صورت اثبات تخلف (در هر زمان) مدرک تحصیلی صادر شده توسط دانشگاه شهید باهنر کرمان از درجه اعتبار ساقط و اینجانب هیچ‌گونه ادعایی نخواهم داشت.

کلیه حقوق مادی و معنوی این اثر (مقالات مستخرج، برنامه‌های رایانه‌ای، نرم افزارها و تجهیزات ساخته شده) مطابق با آیین‌نامه مالکیت فکری، متعلق به دانشگاه شهید باهنر کرمان است و بدون اخذ اجازه کتبی از دانشگاه قابل واگذاری به شخص ثالث نیست. همچنین استفاده از اطلاعات و نتایج این پایان‌نامه بدون ذکر مرجع مجاز نمی‌باشد. چنانچه مبادرت به عملی خلاف این تعهدنامه محرز گردد، دانشگاه شهید باهنر کرمان در هر زمان و به هر نحو مقتضی حق هرگونه اقدام قانونی را در استیفای حقوق خود دارد.

تاریخ و امضا:
علیرضا ایرانمنش
اردیبهشت ۱۴۰۴

^۱ تنها آدرس مورد قبول برای دانشگاه به این صورت می‌باشد:

Shahid Bahonar University of Kerman, Kerman, Iran.

نام و آدرس واحدهای دانشگاه در تولیدات علمی محققان دانشگاه به تشخیص بخش و دانشکده به شرح زیر می‌باشد:

Department of Computer, Faculty of Engineering Shahid Bahonar University of Kerman, Kerman, Iran.

آدرس صحیح جهت درج در مقالات و سایر تولیدات علمی فارسی:

گروه (بخش) کامپیوتر، دانشکده فنی مهندسی، دانشگاه شهید باهنر کرمان، کرمان، ایران.

تقدیم به:

«با نهایت احترام و سپاس، این پایان نامه را تقدیم می‌کنم به:

مهندس علیرضا افضل‌پور و بانو فاخره صبا؛

دو انسان فرهیخته و نیک‌اندیش که با ایثار و آینده‌نگری، بنیان‌گذار دانشگاه شهید باهنر کرمان شدند و مسیر علم و دانش را در این دیار هموار ساختند.

آنها با وقف دارایی و زندگی خود، نهالی از دانش کاشتند که امروز به درختی تناور بدل شده و ثمرات آن در سراسر کشور نمایان است.

یاد و خاطره‌شان همواره الهام‌بخش نسل‌های آینده خواهد بود.»

تشکر و قدردانی:

با سپاس از خداوند بزرگ که به من توانایی و انگیزه برای پیمودن این مسیر علمی را عطا نمود. این پایان‌نامه حاصل تلاش و کوشش‌های فراوان است و بدون حمایت و راهنمایی‌های ارزشمند افراد بسیاری به ثمر نمی‌نشست.

به مصداق شعر «به یاد کسی که در این راه بود، به یاد کسی که در این راه رفت»، شایسته می‌دانم مراتب سپاس و قدردانی صمیمانه خود را تقدیم نمایم به استاد فرهیخته و فرزانه، جناب آقای دکتر حمید میروزی، که با دانش و تجربه‌ی خود همواره راهنمای من بودند و با صبر و شکیبایی به سوالات و ابهاماتم پاسخ دادند، صمیمانه تشکر می‌کنم.

همچنین از دوست عزیزم، محمدحسین شبانی، که با حمایت‌های بی‌دریغ و تشویق‌های همیشگی‌اش، انگیزه و انرژی مضاعفی به من بخشید، قدردانی می‌نمایم.

در پایان، از خانواده‌ی عزیزم که با عشق و محبت بی‌پایان خود همواره پشتیبان من بودند و در تمامی مراحل این مسیر پرچالش، همراه و همدل من بودند، بی‌نهایت سپاسگزارم.

چکیده:

با افزایش روزافزون تهدیدات سایبری، تشخیص بدافزارهای اندرویدی به یکی از چالش‌های اساسی در حوزه امنیت اطلاعات تبدیل شده است. روش‌های سنتی، به‌ویژه آن‌هایی که صرفاً بر تحلیل ویژگی‌های تک‌وجهی تکیه دارند، اغلب قادر به پردازش داده‌های پیچیده چندوجهی نبوده و در مواجهه با تهدیدات جدید، از تعمیم‌پذیری مناسبی برخوردار نیستند. این محدودیت‌ها، ضرورت توسعه رویکردهای نوین و کارآمد را آشکار می‌سازد. در این پژوهش، مدلی چندوجهی با عنوان «تبدیل‌گر چندوجهی مبتنی بر جاسازی گراف دینامیک با توجه پویا» (MAGNET) توسعه داده شد که با ترکیب داده‌های جدولی، گراف و ترتیبی، از جمله توالی فراخوانی‌های API به شناسایی بدافزارهای اندرویدی پرداخت. هدف اصلی، ارتقای دقت و پایداری تشخیص با بهره‌گیری از معماری پیشرفته مبتنی بر یادگیری عمیق و ترنسفورمر بود. در این راستا، بهینه‌سازی هایپرپارامترها با استفاده از الگوریتم‌های پیشرفته‌ای مانند PIRATES و Optuna انجام گرفت و مدل با مجموعه داده‌ای شامل ۴۶۴۱ نمونه آموزشی و ۱۴۵۱ نمونه آزمایشی، همراه با اعتبارسنجی متقاطع پنج‌تایی، آموزش داده شد. ویژگی‌های مورد استفاده شامل ویژگی‌های ایستا نظیر مجوزها، فراخوانی‌های API، مقاصد و نام مؤلفه‌ها و همچنین ویژگی‌های پویا مانند فعالیت شبکه و دسترسی به فایل‌ها بود. داده‌ها به صورت بردارهای عددی باینری یا نرمال‌سازی‌شده آماده‌سازی شدند و پس از پیش‌پردازش، ابعاد ویژگی‌ها به ۴۳۰ ویژگی تنظیم گردید. ابزارهای مورد استفاده شامل کتابخانه‌های یادگیری عمیق مانند PyTorch، تکنیک‌های استانداردسازی و نرمال‌سازی داده‌ها و ساختارهای داده‌ای گرافی بود. نتایج نشان داد که مدل پیشنهادی عملکردی برجسته با دقت بالا، پایداری قابل توجه و قابلیت تعمیم‌پذیری مطلوب ارائه کرد و نسبت به روش‌های پیشین بهبود قابل ملاحظه‌ای داشت. این یافته‌ها، پتانسیل کاربرد مدل در سیستم‌های امنیتی واقعی را برجسته می‌سازد. پیشنهاد می‌شود در تحقیقات آینده، افزایش حجم داده‌ها، ادغام روش‌های خودنظارتی پیشرفته، آزمایش مدل در محیط‌های متنوع‌تر و بهینه‌سازی زمان اجرا مورد توجه قرار گیرد تا کارایی مدل در سناریوهای پیچیده‌تر و واقعی‌تر ارتقا یابد. همچنین، بررسی تأثیر ترکیب داده‌های جدید و توسعه الگوریتم‌های مقاوم در برابر حملات مخرب می‌تواند مسیرهای نوینی برای پژوهش‌های بعدی فراهم آورد.

واژگان کلیدی: تشخیص بدافزار، ترنسفورمر، یادگیری عمیق، داده‌های چندوجهی، امنیت اندروید.

۱	کلیات پژوهش	۱
۲	۱-۱ مقدمه و بیان مسئله	۱-۱
۳	۱-۱-۱ روش‌های تشخیص بدافزار	۱-۱-۱
۳	۲-۱-۱ مجموعه داده‌های مربوطه	۲-۱-۱
۳	۲-۱ ضرورت تحقیق و اهداف	۲-۱
۴	۳-۱ سازماندهی پایان نامه	۳-۱
۶	پیشینه تحقیق و مفاهیم پایه	۲
۷	۱-۲ مقدمه	۱-۲
۸	۲-۲ مفاهیم پایه	۲-۲
۸	۱-۲-۲ تکامل روش‌های یادگیری ماشین	۱-۲-۲
۹	۲-۲-۲ انواع بدافزار	۲-۲-۲
۹	۱-۲-۲-۲ باج‌افزار	۱-۲-۲-۲
۹	۲-۲-۲-۲ تروجان	۲-۲-۲-۲
۱۰	۳-۲-۲-۲ جاسوس‌افزار	۳-۲-۲-۲
۱۰	۴-۲-۲-۲ تبلیغ‌افزار	۴-۲-۲-۲
۱۱	۳-۲-۲ مفاهیم مرتبط با اپلیکیشن‌های اندرویدی	۳-۲-۲
۱۱	۱-۳-۲-۲ مجوزهای دسترسی	۱-۳-۲-۲
۱۲	۲-۳-۲-۲ فایل APK	۲-۳-۲-۲
۱۲	۳-۳-۲-۲ سورس‌کد	۳-۳-۲-۲
۱۳	۴-۲-۲ داده‌های چندوجهی در تشخیص بدافزار	۴-۲-۲
۱۳	۱-۴-۲-۲ داده‌های جدولی	۱-۴-۲-۲
۱۳	۲-۴-۲-۲ داده‌های گرافیکی	۲-۴-۲-۲
۱۴	۳-۴-۲-۲ داده‌های ترتیبی	۳-۴-۲-۲
۱۴	۴-۴-۲-۲ اهمیت و یکپارچگی داده‌های چندوجهی	۴-۴-۲-۲
۱۵	۵-۲-۲ مدل‌های یادگیری عمیق	۵-۲-۲
۱۵	۱-۵-۲-۲ شبکه‌های عصبی کانولوشنی (CNN)	۱-۵-۲-۲

شبکه‌های عصبی بازگشتی و واحدهای حافظه بلند- کوتاه	۲-۵-۲-۲
(RNN و LSTM)	۱۵
شبکه‌های عصبی گرافی (GNN)	۳-۵-۲-۲
۱۷	
ترنسفورمرها	۶-۲-۲
۱۷	
۰-۶-۲-۲- (معرفی ترنسفورمر و تحول در مدل‌های یادگیری عمیق	۱۷
ترنسفورمرها در مدل MAGNET	۷-۲-۲
۱۹	
ماشین بردار پشتیبان (SVM)	۸-۲-۲
۲۰	
انواع SVM	۲۰-۸-۲-۲
۲۰	
کاربرد در تشخیص بدافزار	۲۰-۸-۲-۲
۲۱	
مزایا و معایب	۲۰-۸-۲-۲
۲۱	
تکنیک‌های آموزشی و ارزیابی	۳-۲
۲۲	
اعتبارسنجی متقاطع (Cross-Validation)	۱-۳-۲
۲۲	
مدیریت اورفیتینگ و آندرفیتینگ	۲-۳-۲
۲۳	
روش‌های بهینه‌سازی	۳-۳-۲
۲۴	
الگوریتم Adam	۱-۳-۳-۲
۲۴	
الگوریتم PIRATES	۲-۳-۳-۲
۲۴	
الگوریتم Optuna	۳-۳-۳-۲
۲۵	
معیارهای ارزیابی عملکرد	۴-۳-۲
۲۶	
دقت (Accuracy)	۱-۴-۳-۲
۲۶	
Score F۱	۲-۴-۳-۲
۲۷	
(Area Under the ROC Curve) AUC	۳-۴-۳-۲
۲۸	
۳-۴-۳-۲- اجمع‌بندی ارزیابی	۲۸
۲۹	
مروری بر مطالعات پیشین	۴-۲
۲۹	
روش‌های تحلیل ایستا	۱-۴-۲
۲۹	
تحلیل ویژگی‌های مبتنی بر مانیفست و متاداده	۱-۱-۴-۲
۲۹	
تحلیل کد (Code Analysis)	۲-۱-۴-۲
۲۹	
تحلیل ایستای ساختاری	۳-۱-۴-۲
۳۰	
۳-۱-۴-۲- محدودیت‌های تحلیل ایستا	۳۰
۳۰	
روش‌های تحلیل پویا	۲-۴-۲
۳۰	

۳۱	مانیتورینگ رفتار سیستم	۱-۲-۴-۲
۳۱	تحلیل شبکه	۲-۲-۴-۲
۳۱	بررسی مصرف منابع	۳-۲-۴-۲
۳۱	ابزارها و محیط‌های تحلیل پویا	۳-۲-۴-۲
۳۱	محدودیت‌های تحلیل پویا	۳-۲-۴-۲
۳۲	روش‌های ترکیبی (Hybrid Approaches)	۴-۲-۴-۲
۳۲	کارهای پیشین و تاریخچه مختصر	۳-۴-۲
۳۳	جمع‌بندی فصل	۵-۲

۳۴	روش پیشنهادی	۳
۳۵	روش پیشنهادی	۱-۳
۳۵	مقدمه روش پیشنهادی	۱-۱-۳
۳۶	فرضیات و ابزارهای محاسباتی	۲-۱-۳
۳۶	فرضیات	۱-۲-۱-۳
۳۷	ابزارهای محاسباتی	۲-۲-۱-۳
۳۸	روش‌شناسی	۳-۱-۳
۳۸	پیش‌پردازش داده‌ها	۱-۳-۱-۳
۳۹	طراحی مدل MAGNET	۲-۳-۱-۳
۳۹	EnhancedTabTransformer (ماژول جدولی)	۱-۳-۲-۳-۱-۳
۴۰	GraphTransformer (ماژول گرافی)	۲-۳-۱-۳-۲-۳
۴۰	SequenceTransformer (ماژول ترتیبی)	۳-۲-۳-۱-۳-۲-۳
۴۱	مکانیزم توجه پویا	۴-۲-۳-۱-۳-۲-۳
۴۲	دغام چندوجهی	۵-۲-۳-۱-۳-۲-۳
۴۲	مدل نهایی MAGNET	۲-۳-۱-۳-۲-۳
۴۲	آموزش مدل	۳-۳-۱-۳-۲-۳
۴۳	بهینه‌سازی ابرپارامترها	۴-۳-۱-۳-۲-۳
۴۳	ارزیابی مدل	۵-۳-۱-۳-۲-۳
۴۳	جمع‌بندی روش پیشنهادی	۴-۱-۳-۲-۳

۴۶	نتایج و بحث	۴
----	-------------	---

۴۷	مقدمه	۱-۴
۴۷	تنظیمات آزمایشی	۲-۴
۴۷	ویژگی های داده	۱-۲-۴
۴۸	پیکربندی آزمایش ها	۲-۲-۴
۴۹	تحلیل فرآیند بهینه سازی با الگوریتم Pirates	۳-۴
۴۹	نمایش موقعیت کشتی ها و رهبر	۱-۳-۴
۴۹	روند تغییر هزینه و همگرایی	۲-۳-۴
۵۰	تحلیل پویایی جمعیت: باد، سرعت و شتاب	۳-۳-۴
۵۱	جمع بندی تحلیل فرآیند بهینه سازی	۴-۳-۴
۵۲	تحلیل حساسیت پارامترهای الگوریتم	۴-۴
۵۲	تحلیل حساسیت پارامترهای معماری مدل	۱-۴-۴
۵۲	تحلیل حساسیت پارامترهای آموزش	۲-۴-۴
۵۳	مقایسه حساسیت بین الگوریتم های بهینه سازی	۳-۴-۴
۵۳	توصیه های عملی	۴-۴-۴
۵۴	مدل های پایه	۵-۴-۴
۵۴	محیط اجرا	۶-۴-۴
۵۵	معیارهای ارزیابی	۵-۴
۵۶	ارزیابی جامع مدل MAGNET	۶-۴
۵۶	تحلیل عملکرد	۱-۶-۴
۵۶	تحلیل خطا	۱-۱-۶-۴
۵۷	تحلیل ROC و PR	۲-۱-۶-۴
۵۷	تحلیل پایداری	۲-۶-۴
۵۷	تحلیل حساسیت به نویز	۱-۲-۶-۴
۵۸	تحلیل پایداری در طول زمان	۲-۲-۶-۴
۵۸	تحلیل مقیاس پذیری	۳-۶-۴
۵۸	تحلیل کارایی محاسباتی	۱-۳-۶-۴
۵۹	تحلیل مقیاس پذیری داده	۲-۳-۶-۴
۵۹	تحلیل کارایی	۴-۶-۴
۵۹	تحلیل هزینه-فایده	۱-۴-۶-۴

۶۰	تحلیل قابلیت استقرار	۲-۴-۶-۴
۶۱	جمع‌بندی ارزیابی	۵-۶-۴
۶۲	نتیجه‌گیری و پیشنهادات آتی	۵
۶۳	نتیجه‌گیری	۱-۵
۶۳	پیشنهادات آتی	۲-۵
۶۳	پژوهش‌های تکمیلی	۱-۲-۵
۶۴	پیشنهادات اجرایی	۲-۲-۵
۶۴	تولید داده‌های جدید	۳-۲-۵
۶۵	مراجع	۶
۶۹	پیوست	
۷۰	پیوست A: کدهای پیاده‌سازی مدل MAGNET	۱-
۷۰	کد معماری مدل MAGNET	۱-۱-
۷۱	کد بهینه‌سازی با PIRATES	۲-۱-
۷۲	پیوست B: داده‌های خام و پیش‌پردازش	۲-
۷۲	نمونه داده‌های خام DREBIN	۱-۲-
۷۳	توضیحات پیش‌پردازش	۲-۲-
۷۳	پیوست C: جزئیات سخت‌افزاری و نرم‌افزاری	۳-
۷۳	مشخصات سخت‌افزاری	۱-۳-
۷۳	مشخصات نرم‌افزاری	۲-۳-
۷۴	پیوست D: نتایج اضافی و ماتریس‌های کامل	۴-
۷۴	ماتریس درهم‌ریختگی کامل	۱-۴-
۷۴	گزارش طبقه‌بندی برای هر دسته	۲-۴-

فهرست جداول

صفحه	عنوان
۷۳	جدول ۱ نمونه‌ای از داده‌های خام دیتاست DREBIN
۷۴	جدول ۲ ماتریس درهم‌ریختگی برای مجموعه تست
۷۴	جدول ۳ گزارش طبقه‌بندی برای هر دسته در اعتبارسنجی متقاطع

- شکل ۱-۲ ساختار کلی یک شبکه عصبی کانولوشنی (CNN) ابتدا تصویر ورودی یا ماتریس ویژگی وارد شبکه می‌شود. در مرحله استخراج ویژگی، لایه‌های کانولوشنی و تجمعی به ترتیب ویژگی‌های محلی را استخراج و ابعاد داده را کاهش می‌دهند. سپس داده‌ها به یک بردار یک‌بعدی تبدیل شده (Flattening) و وارد لایه‌های کاملاً متصل می‌شوند تا فرایند طبقه‌بندی نهایی انجام گیرد. این ساختار باعث می‌شود شبکه بتواند به صورت خودکار و بدون نیاز به مهندسی ویژگی دستی، الگوهای پیچیده را شناسایی کند. برگرفته از [۱۰]. ۱۶
- شکل ۲-۲ نمایی از یک مدل شبکه عصبی گرافی (GNN) ابتدا گراف ورودی (با ویژگی‌های اولیه گره‌ها و ساختار اتصالات) به مدل داده می‌شود. سپس در چندین بلوک GNN (لایه)، اطلاعات گره‌ها با تجمیع اطلاعات از همسایگان و به‌روزرسانی با استفاده از شبکه‌های عصبی کوچک، به‌طور مکرر پالایش می‌شود تا بازنمایی‌های غنی‌تری (گراف تبدیل‌شده) حاصل شود. در نهایت، این بازنمایی‌ها می‌توانند برای وظایف مختلف مانند طبقه‌بندی کل گراف (مثلاً بدافزار/سالم)، طبقه‌بندی گره‌ها (مثلاً شناسایی توابع مخرب) یا پیش‌بینی لبه‌ها استفاده شوند. برگرفته و بازطراحی شده بر اساس [۱۳]. ۱۸
- شکل ۳-۲ ساختار کلی معماری ترنسفورمر شامل بخش کدگذار (Encoder) در سمت چپ و گشاینده (Decoder) در سمت راست. هر دو بخش از پشته‌ای از لایه‌های یکسان تشکیل شده‌اند که عمدتاً شامل مکانیزم توجه چندسر (Multi-Head Attention) و شبکه‌های عصبی پیش‌خور (Feed Forward) هستند. اتصالات باقیمانده (Add) و نرمال‌سازی لایه‌ای (Norm) نیز برای پایداری آموزش استفاده می‌شوند. گشاینده علاوه بر توجه خودی، از توجه متقابل (Cross-Attention) برای در نظر گرفتن خروجی کدگذار نیز بهره می‌برد. این معماری امکان پردازش موازی و مدل‌سازی وابستگی‌های بلندمدت را فراهم می‌کند. برگرفته و بازطراحی شده بر اساس [۱۶]. ۲۰
- شکل ۱-۳ معماری مدل MAGNET شامل سه ماژول تخصصی (EnhancedTabTrans، GraphTransformer، former، SequenceTransformer) لایه ادغام چندوجهی و طبقه‌بند باینری. ۳۹

- شکل ۴-۱ نمایش موقعیت کشتی‌ها، (Ships) رهبر، (Leader) نقشه، (Map) کشتی‌های
 برتر (Top Ships) و کشتی‌های غیرهمگرا (Un-Conv) در فضای جستجو. ۴۹
- شکل ۴-۲ روند تغییر بهترین مقدار هزینه، (BSF) میانگین هزینه، (Average) مقایسه BSF
 و Average و مسیر رهبر (Trajectory) در طول تکرارها. ۵۰
- شکل ۴-۳ تغییرات سرعت، (Velocity) باد، (Wind) نیروی محرکه (F) و شتاب (Ac-
 celeration) کشتی‌ها در طول تکرارها. ۵۱

فهرست الگوریتم‌ها

صفحه	عنوان
۴۰	الگوریتم ۱-۳ Structure Module EnhancedTabTransformer
۴۱	الگوریتم ۲-۳ Structure Module GraphTransformer
۴۱	الگوریتم ۳-۳ Structure Module SequenceTransformer
۴۱	الگوریتم ۴-۳ Mechanism Attention Dynamic
۴۲	الگوریتم ۵-۳ Fusion Modality
۴۲	الگوریتم ۶-۳ Model MAGNET Final

فصل اول:
کلیات پژوهش

۱-۱ مقدمه و بیان مسئله

در سال‌های اخیر، گسترش تلفن‌های همراه و به‌ویژه سیستم عامل اندروید^۱، موجب افزایش وابستگی کاربران به این ابزارها شده است. این دستگاه‌ها نه تنها در زندگی روزمره، بلکه در حوزه‌های تجاری و نظامی نیز نقش مهمی ایفا می‌کنند. با این حال، محبوبیت و فراگیری اندروید، آن را به هدفی جذاب برای حملات بدافزاری^۲ تبدیل کرده است. عرضه نرم‌افزارهای غیرمعتبر و تهدیداتی مانند ویروس‌ها و بدافزارها، امنیت کاربران را به خطر انداخته است. مطالعات اخیر نشان می‌دهد که بیش از 70 درصد دستگاه‌های هوشمند از سیستم عامل اندروید استفاده می‌کنند و این امر باعث شده است که این پلتفرم به هدف اصلی حملات امنیتی تبدیل شود [۱]. با وجود پیشرفت‌های قابل توجه در روش‌های تشخیص بدافزار، همچنان چالش‌های جدی در شناسایی بدافزارهای جدید و پیچیده وجود دارد.

در ابتدا، روش‌های سنتی مبتنی بر تحلیل مجوزها^۳ و بازکردن فایل‌ها مورد استفاده قرار می‌گرفتند که به دلیل دقت پایین و ضعف در شناسایی بدافزارهای پیچیده، محدودیت‌هایی داشتند. پژوهش‌های اخیر نشان داده‌اند که روش‌های مبتنی بر یادگیری ماشین^۴ و یادگیری عمیق^۵ می‌توانند عملکرد بهتری در تشخیص بدافزارها داشته باشند [۲]. با این حال، همچنان چالش‌های مهمی در زمینه تفسیرپذیری مدل‌ها^۶ و قابلیت تعمیم‌پذیری^۷ وجود دارد. این چالش‌ها به ویژه در مواجهه با بدافزارهای جدید و ناشناخته (Zero-Day)^۸ بیشتر خود را نشان می‌دهند.

مدل MAGNET^۹ که در این پژوهش معرفی شده است، با بهره‌گیری از معماری ترنسفورمر^{۱۰} چندوجهی و ترکیب داده‌های جدولی، گراف و توالی، تلاش می‌کند تا این چالش‌ها را برطرف کند. این مدل با استفاده از مکانیزم‌های توجه پویا^{۱۱} و تحلیل همزمان داده‌های مختلف، قادر به تشخیص دقیق‌تر بدافزارها خواهد بود. نتایج نشان می‌دهد که این رویکرد با دقت $97.24\% \pm 0.5\%$ ، معیار $F1 = 0.9823 \pm 0.002$ ، و معیار $AUC = 0.9932 \pm 0.003$ عملکرد بهتری نسبت به مدل‌های پایه مانند SVM (دقت 90.6%)، CNN (دقت 92.8%) و LSTM (دقت 91.5%) دارد.

¹ Android

² Malware

³ Permissions

⁴ Machine Learning

⁵ Deep Learning

⁶ Model Interpretability

⁷ Generalization

⁸ Zero-Day

⁹ MAGNET (Multi-Modal Analysis for Graph and Network Threat Detection)

¹⁰ Transformer

¹¹ Attention Mechanism

۱-۱-۱ روش‌های تشخیص بدافزار

تشخیص بدافزارهای اندرویدی به دو روش کلی پویا^۱ و ایستا^۲ انجام می‌شود. در روش پویا، رفتار اپلیکیشن در زمان اجرا مانند مصرف باتری، پردازنده یا ترافیک شبکه بررسی می‌شود تا الگوهای غیرعادی شناسایی گردد. این روش به‌تنهایی کافی نیست و ممکن است برخی تهدیدات پنهان را نادیده بگیرد. روش ایستا با تحلیل ساختار و کد اپلیکیشن، مانند بررسی فراخوانی‌های API^۳ و مجوزها، اطلاعات ارزشمندی ارائه می‌دهد که می‌تواند در تشخیص دقیق‌تر کمک کند. پژوهش‌های اخیر نشان داده‌اند که ترکیب این دو روش می‌تواند نتایج بهتری در تشخیص بدافزارها ارائه دهد [۳].

۲-۱-۱ مجموعه داده‌های مربوطه

در حوزه تشخیص بدافزار اندروید، مجموعه داده‌های متنوعی برای ارزیابی عملکرد مدل‌ها مورد استفاده قرار گرفته‌اند. از جمله این مجموعه داده‌ها می‌توان به موارد زیر اشاره کرد:

- مجموعه داده‌های Drebin [۴] و AndroZoo [۵] که شامل نمونه‌های گسترده‌ای از بدافزارها و برنامه‌های سالم اندرویدی هستند.
- مجموعه داده‌های CICMalDroid [۶] و VirusShare که شامل نمونه‌های جدید و به‌روز از بدافزارها می‌باشند.
- مجموعه داده‌های خصوصی و صنعتی که توسط شرکت‌های امنیتی و مراکز تحقیقاتی گردآوری شده‌اند.

این مجموعه داده‌ها به عنوان شاخص‌های استاندارد، امکان ارزیابی دقیق و جامع عملکرد الگوریتم‌های تشخیص بدافزار را فراهم می‌کنند و نقش مهمی در اثبات قابلیت تعمیم و کارایی روش‌های پیشنهادی دارند.

۲-۱-۲ ضرورت تحقیق و اهداف

پلتفرم اندروید به دلیل محبوبیت گسترده و سهم عظیمش از بازار جهانی، به هدف اصلی بدافزارها و حملات امنیتی تبدیل شده است. این سیستم عامل، که بیش از 70 درصد دستگاه‌های هوشمند را پشتیبانی می‌کند، به دلیل ساختار باز و دسترسی‌پذیری بالا، با تهدیدات پیشرفته‌ای مواجه است. بدافزارهای اندرویدی،

¹Dynamic Analysis

²Static Analysis

³API

از جمله تروجان‌ها^۱، جاسوس‌افزارها^۲ و باج‌افزارها^۳، با روش‌های پیچیده‌ای طراحی شده‌اند و پیشرفت‌های چشمگیری داشته‌اند. این تهدیدات، از سرقت اطلاعات حساس گرفته تا ایجاد اختلال در عملکرد دستگاه‌ها، چالش‌های امنیتی جدی ایجاد کرده‌اند. از این رو، نیاز به سیستمی قدرتمند و کارآمد برای تشخیص بدافزارهای اندرویدی بیش از پیش احساس می‌شود. هدف اصلی این پژوهش، تمرکز بر شناسایی بدافزارهای ناشناخته و نادیده (Zero-Day)^۴ است که تا کنون شناسایی نشده‌اند و می‌توانند تهدیداتی پنهان برای کاربران ایجاد کنند.

با توجه به چالش‌ها و نیازهای مطرح شده، اهداف اصلی این تحقیق بدین شرح می‌باشد:

- توسعه یک مدل چندوجهی پیشرفته با نام MAGNET که قادر به تحلیل همزمان داده‌های جدولی، گرافی و ترتیبی باشد.
- بهبود دقت تشخیص بدافزارهای اندرویدی با استفاده از معماری ترنسفورمر و مکانیزم‌های توجه پویا^۵.
- کاهش نرخ خطای تشخیص و افزایش قابلیت تعمیم‌پذیری مدل در مواجهه با بدافزارهای جدید.
- بهینه‌سازی مصرف منابع محاسباتی و افزایش سرعت تشخیص با استفاده از الگوریتم‌های پیشرفته.
- ایجاد یک چارچوب استاندارد برای ارزیابی و مقایسه روش‌های مختلف تشخیص بدافزار.

۱-۳ سازماندهی پایان نامه

در این پایان‌نامه، ساختار مطالب به گونه‌ای تدوین شده که مسیر پژوهش از مبانی نظری و معرفی مسئله تا ارائه نتایج تجربی به صورت پیوسته و منطقی دنبال شود. به عبارت دیگر، هدف از سازماندهی مطالب این است که خواننده بتواند به راحتی با مباحث پایه، چالش‌ها، روش‌های موجود و نوآوری‌های پیشنهادی آشنا شود و در نهایت به درک جامع از دستاوردهای تحقیق دست یابد. ساختار کلی پایان‌نامه به شرح زیر است:

• فصل ۲ - پیشینه تحقیق و مفاهیم پایه:

در این فصل، ابتدا به بررسی کلی امنیت اندروید و اهمیت تشخیص بدافزار پرداخته می‌شود. سپس، چالش‌ها و محدودیت‌های روش‌های سنتی بیان شده و مسئله تحقیق به تفصیل معرفی می‌شود. هدف این فصل ایجاد زمینه نظری مناسب برای درک اهمیت تشخیص خودکار بدافزارهاست.

¹Trojan

²Spyware

³Ransomware

⁴Zero-Day

⁵Attention Mechanism

در ادامه به بررسی جامع مطالعات پیشین در حوزه تشخیص بدافزار اندروید پرداخته می‌شود. در این بخش، رویکردهای مختلف از جمله روش‌های مبتنی بر یادگیری ماشین و یادگیری عمیق مورد تحلیل قرار می‌گیرند. نقاط قوت و ضعف هر یک از این رویکردها همراه با چالش‌های موجود در هر کدام به تفصیل بررسی می‌شود.

- فصل 3 – روش پیشنهادی (MAGNET):

در این فصل، مدل پیشنهادی MAGNET به صورت کامل تشریح می‌شود. ابتدا معماری کلی مدل و اجزای اصلی آن معرفی می‌شوند. سپس، جزئیات پیاده‌سازی و الگوریتم‌های بهینه‌سازی مورد استفاده توضیح داده می‌شود. در نهایت، نوآوری‌های اصلی این روش نسبت به سایر روش‌ها برجسته می‌شود.

- فصل 4 – نتایج و بحث:

این فصل به ارائه نتایج آزمایش‌های انجام شده بر روی چندین مجموعه داده معتبر اختصاص دارد. عملکرد مدل MAGNET از نظر دقت، کارایی و صرفه‌جویی در منابع محاسباتی مورد مقایسه قرار گرفته و نتایج به دست آمده تحلیل می‌شوند.

- فصل 5 – نتیجه‌گیری و پیشنهادات آتی:

در فصل نهایی، یافته‌های اصلی تحقیق به طور خلاصه ارائه شده و به نتیجه‌گیری کلی از دستاوردهای پژوهش پرداخته می‌شود. در این بخش، چالش‌های باقی‌مانده، محدودیت‌های تحقیق و نیز پیشنهاداتی جهت تحقیقات آتی و بهبود رویکرد ارائه می‌شود.

فصل دوم:

پیشینه تحقیق و مفاهیم پایه

در سال‌های اخیر، با گسترش روزافزون استفاده از دستگاه‌های هوشمند مبتنی بر سیستم عامل اندروید، امنیت سایبری به یکی از دغدغه‌های اصلی کاربران و سازمان‌ها تبدیل شده است. محبوبیت گسترده اندروید، که طبق آمار Statista در سال ۲۰۲۴ بیش از ۷۰ درصد بازار جهانی دستگاه‌های هوشمند را در اختیار دارد [۷]، آن را به هدف اصلی حملات بدافزاری، از جمله تروجان‌ها^۱، جاسوس‌افزارها^۲ و باج‌افزارها^۳، مبدل ساخته است [۱]. این تهدیدات، با بهره‌گیری از روش‌های پیچیده و نوظهور، چالش‌های جدی در شناسایی و خنثی‌سازی ایجاد کرده‌اند، به‌ویژه در مورد بدافزارهای ناشناخته (Zero-Day)^۴ که تشخیص آن‌ها با روش‌های سنتی مبتنی بر امضا دشوار است [۳]. از این رو، توسعه مدل‌های پیشرفته مبتنی بر یادگیری عمیق و داده‌های چندوجهی، به‌عنوان راهکاری نوین برای مقابله با این تهدیدات، مورد توجه فزاینده‌ای قرار گرفته است [۲].

فصل حاضر به‌عنوان پایه‌ای برای درک روش پیشنهادی این پژوهش، به بررسی مفاهیم پایه و مرور مطالعات پیشین در حوزه تشخیص بدافزارهای اندرویدی می‌پردازد. ابتدا، مفاهیم کلیدی و اصطلاحات فنی مورد نیاز معرفی خواهند شد. سپس، تکنیک‌های رایج یادگیری ماشین و یادگیری عمیق که در این حوزه کاربرد دارند، تشریح می‌شوند. در ادامه، ابزارها و روش‌های بهینه‌سازی مانند ترنسفورمرها^۵، الگوریتم‌های PIRATES و Optuna^۶، که در طراحی مدل MAGNET (روش پیشنهادی این پژوهش) به کار رفته‌اند، معرفی خواهند شد. همچنین، تکنیک‌های آموزشی و معیارهای ارزیابی عملکرد، نظیر اعتبارسنجی متقاطع^۷ و معیارهای دقت^۸، F1 Score^۹ و AUC^{۱۰}، به‌منظور تبیین چارچوب ارزیابی مدل توضیح داده می‌شوند.

در بخش بعدی، پیشینه تحقیق با تمرکز بر روش‌های تحلیل ایستا^{۱۱} و پویا^{۱۲}، که پایه‌های اصلی تشخیص بدافزار را تشکیل می‌دهند، مورد بررسی قرار می‌گیرد. این مرور، با تحلیل نقاط قوت و ضعف روش‌های پیشین، زمینه‌ای برای درک نوآوری‌های مدل پیشنهادی فراهم می‌کند. هدف این فصل، ارائه دیدگاهی جامع و منسجم از مفاهیم و مطالعات مرتبط است تا خواننده را برای درک بهتر روش‌شناسی و نتایج پژوهش آماده سازد. این ساختار، نه تنها به تبیین مسائل نظری کمک می‌کند، بلکه راه را برای مقایسه و ارزیابی عملکرد

¹Trojan²Spyware³Ransomware⁴Zero-Day⁵Transformer⁶Optuna⁷Cross-Validation⁸Accuracy⁹و¹⁰Area Under Curve (AUC)¹¹Static Analysis¹²Dynamic Analysis

۲-۲ مفاهیم پایه

در این بخش، مفاهیم بنیادی مرتبط با موضوع پژوهش، از جمله تاریخچه مختصری از یادگیری ماشین، انواع بدافزارها، ساختار اپلیکیشن‌های اندروید، داده‌های چندوجهی و مدل‌های یادگیری عمیق مرتبط، تشریح می‌شوند.

۱-۲-۲ تکامل روش‌های یادگیری ماشین

در دهه‌های ۱۹۵۰ و ۱۹۶۰، اولین تلاش‌ها برای پردازش زبان طبیعی به وسیله‌ی روش‌های نمادین انجام شد. پژوهشگران در آن زمان سعی می‌کردند ساختارهای دستوری و قوانین زبان را به صورت صریح و دستی تعریف کنند. این رویکردها با وجود تلاش‌های ارزشمند، به دلیل محدودیت‌های محاسباتی و عدم وجود داده‌های کافی، نتوانستند به دقت و کارایی مورد انتظار دست یابند.

با گذر زمان و ورود به دهه‌های ۱۹۶۰ و ۱۹۷۰، رویکردهای آماری جایگزین بخش‌هایی از روش‌های نمادین شدند. در این دوران، مدل‌های n-gram که بر مبنای احتمال وقوع یک کلمه با توجه به کلمات قبلی محاسبه می‌شدند، به عنوان اولین قدم‌های موفق در مدلسازی زبان مطرح شدند. اگرچه این مدل‌ها ساده بودند، اما توانستند برخی از پیچیدگی‌های اولیه‌ی پردازش زبان را کاهش دهند.

در دهه‌های ۱۹۸۰ و ۱۹۹۰، با پیشرفت‌های چشمگیر در فناوری‌های محاسباتی و افزایش دسترسی به داده‌های متنی، روش‌های یادگیری ماشین وارد عرصه شدند. الگوریتم‌های یادگیری نظارت‌شده و غیرنظارتی به منظور تشخیص الگوهای زبانی به کار گرفته شدند. با این حال، محدودیت‌های موجود همچنان مانع از دستیابی به درک عمیق‌تر و تولید متن‌های طبیعی به سطح امروزی می‌شدند.

ورود به قرن ۲۱ و به‌ویژه دهه ۲۰۱۰، با ظهور شبکه‌های عصبی عمیق مانند شبکه‌های عصبی کانولوشنی^۱، شبکه‌های عصبی بازگشتی^۲ و شبکه‌های حافظه بلندمدت- کوتاه‌مدت^۳ همراه بود. این مدل‌ها توانستند وابستگی‌های زمانی، الگوهای تصویری و روابط بلندمدت موجود در داده‌ها را بهتر مدل‌سازی کنند [۸]. با این حال، چالش‌هایی همچنان در زمینه بهبود کیفیت و کارایی تحلیل داده‌های پیچیده مانند کدهای بدافزار وجود داشت که منجر به توسعه معماری‌های پیشرفته‌تری مانند ترنسفورمرها شد.

^۱ Convolutional Neural Networks (CNNs)

^۲ Recursive Neural Networks (RNNs)

^۳ Long Short-Term Memory (LSTM)

۲-۲-۲ انواع بدافزار

بدافزار (Malware) اصطلاحی کلی برای هر نوع نرم افزار مخرب است که با هدف آسیب رساندن به سیستم ها، سرقت اطلاعات یا اختلال در عملکرد طراحی می شود. در ادامه، برخی از رایج ترین انواع بدافزارها معرفی می شوند:

۱-۲-۲-۲ باج افزار

باج افزار^۱ گونه ای از بدافزارها است که با سرعت زیادی گسترش یافته و امروزه به شکل فراگیری در حال شیوع است. باج افزارها عمدتاً به دو نوع قفل کننده (کریپتور)^۲ و مسدودکننده^۳ تقسیم می شوند. پس از آلوده سازی رایانه، نوع قفل کننده داده های ارزشمند کاربر از جمله اسناد، تصاویر و پایگاه های داده را رمزنگاری می کند و تا زمانی که رمزگشایی نشوند، هیچ فایلی قابل دسترسی نخواهد بود. مهاجمان در ازای ارائه کلید رمزگشا برای بازگرداندن فایل های قفل شده، درخواست باج می کنند. نوع مسدودکننده نیز دسترسی به کل سیستم آلوده را مسدود می کند و معمولاً میزان باج خواهی آن کمتر از نوع قفل کننده است.

باج افزارها می توانند سیستم عامل های مختلفی مانند ویندوز، مک او اس^۴، لینوکس و اندروید را هدف قرار دهند و هم رایانه های دسکتاپ و هم دستگاه های موبایل را آلوده سازند [۱]. آلودگی معمولاً از طریق باز کردن فایل های ضمیمه مخرب، کلیک روی لینک های مشکوک یا نصب برنامه ها از منابع غیررسمی رخ می دهد. حتی وب سایت های رسمی نیز گاهی به واسطه شبکه های تبلیغاتی آلوده می شوند. حذف باج افزارها معمولاً دشوار است و در صورت رمزنگاری فایل ها، کاربر باید برای بازیابی دسترسی، رمزگشایی انجام دهد که پرداخت باج نیز تضمینی برای بازگشت اطلاعات نیست و توصیه نمی شود.

۲-۲-۲-۲ تروجان

تروجان^۵ یا اسب تروآ، نوعی برنامه مخرب است که خود را به عنوان نرم افزاری مشروع و بی خطر جلوه می دهد تا کاربر را فریب داده و به سیستم نفوذ کند. نام گذاری این بدافزار برگرفته از داستان اسب چوبی تروای یونانیان است که با حيله وارد شهر شد. انواع مختلفی از تروجان ها وجود دارد، از جمله:

- **تروجان دسترسی از راه دور (Backdoor):** به مهاجم امکان کنترل سیستم قربانی از راه دور را می دهد.

¹Ransomware

²Cryptor

³Locker

⁴Mac OS X

⁵Trojan Horse

- **تروجان ارسال داده:** اطلاعات حساس مانند رمزهای عبور و داده‌های وارد شده توسط کاربر را به مهاجم ارسال می‌کند.
- **تروجان مخرب:** فایل‌های سیستمی را حذف یا تخریب می‌کند.
- **تروجان DoS:** باعث کاهش سرعت سیستم و اینترنت کاربر می‌شود (حملات منع سرویس).
- **تروجان پراکسی:** به مهاجم اجازه می‌دهد از طریق سیستم قربانی به سرورهای پراکسی حمله کند.
- **تروجان FTP:** پورت FTP را باز کرده و کنترل سیستم را از این طریق به مهاجم می‌دهد.
- **تروجان غیرفعال سازی امنیت:** نرم‌افزارهای امنیتی را غیرفعال می‌کند تا حمله آسان‌تر انجام شود.

۳-۲-۲-۲ جاسوس افزار

جاسوس افزار^۱ نوعی نرم‌افزار مخرب است که بدون اطلاع کاربر، اطلاعاتی درباره او یا فعالیت‌هایش را جمع‌آوری و برای مهاجم ارسال می‌کند. کاربردهای رایج جاسوس افزارها شامل تبلیغات هدفمند، جمع‌آوری اطلاعات شخصی (مانند اطلاعات بانکی یا رمزهای عبور) و ایجاد تغییرات ناخواسته در تنظیمات سیستم قربانی است. این بدافزارها می‌توانند باعث کاهش کارایی سیستم، نصب نوار ابزارهای ناخواسته، تغییر صفحه خانگی مرورگر و باز شدن صفحات پاپ‌آپ تبلیغاتی شوند.

۴-۲-۲-۲ تبلیغ افزار

تبلیغ افزار^۲ نرم‌افزاری است که با هدف نمایش تبلیغات ناخواسته روی سیستم قربانی طراحی شده است. این تبلیغات معمولاً به صورت بنرها یا صفحات پاپ‌آپ ظاهر می‌شوند و گاهی صفحات اینترنتی متعددی را به طور متوالی باز می‌کنند. اگرچه همه تبلیغ افزارها ذاتاً مخرب نیستند (برخی نرم‌افزارهای رایگان از طریق نمایش تبلیغ درآمدزایی می‌کنند)، اما انواع تهاجمی آن‌ها می‌توانند فعالیت‌های آنلاین کاربر را دنبال کرده و تجربه کاربری را مختل کنند. همچنین، برخی تبلیغ افزارها اطلاعات مربوط به رفتار کاربر را جمع‌آوری و برای اهداف تبلیغاتی یا حتی فروش به اشخاص ثالث ارسال می‌کنند که می‌تواند حریم خصوصی را نقض کند.

^۱ Spyware

^۲ Adware

۳-۲-۲ مفاهیم مرتبط با اپلیکیشن‌های اندرویدی

۱-۳-۲-۲ مجوزهای دسترسی

اندروید از یک سیستم تخصیص مجوز^۱ برخوردار است که برای هر عملیات یا وظیفه (Task) حساس، مجوزها و سطوح دسترسی خاصی را تعیین می‌کند. هر اپلیکیشن می‌تواند برای انجام عملیات خاص، مجوزهای لازم را از این سامانه درخواست نماید. به عنوان مثال، یک برنامه کاربردی ممکن است برای دسترسی به اینترنت، دوربین، یا لیست مخاطبین، مجوزهای مربوطه را درخواست کند. این سیستم دارای سطوح مختلفی برای مجوزها است که به آن‌ها سطح حفاظت (Protection Level) گفته می‌شود.

در نسخه‌های قدیمی‌تر اندروید (قبل از نسخه ۰.۶)، اپلیکیشن‌ها هنگام نصب، لیست تمامی مجوزهای مورد نیاز خود را به کاربر اعلام می‌کردند و کاربر یا همه را می‌پذیرفت یا نصب را لغو می‌کرد. اما از نسخه ۰.۶ اندروید (Marshmallow، API سطح ۲۳) به بعد، مدل مجوزدهی پویا (Runtime Permissions) معرفی شد که طی آن، مجوزهای حساس تنها در زمان اجرای برنامه و هنگامی که اپلیکیشن برای اولین بار به آن قابلیت نیاز دارد، از کاربر درخواست می‌شوند. اپلیکیشن‌های اندرویدی مجوزهای مورد نیاز خود را در فایل مانیفست اندروید (AndroidManifest.xml) اعلام می‌کنند. همچنین، اپلیکیشن می‌تواند مجوزهای اضافی را در این فایل تعریف کند که دسترسی به برخی اجزای داخلی نرم‌افزار توسط سایر برنامه‌ها را محدود می‌سازد.

در اندروید، مجوزها عمدتاً به دو سطح دسترسی و امنیت تقسیم می‌شوند:

- **معمولی (Normal):** مجوزهایی که ریسک پایینی برای حریم خصوصی کاربر یا عملکرد سایر اپلیکیشن‌ها دارند (مانند مجوز دسترسی به اینترنت یا تنظیم منطقه زمانی). این مجوزها معمولاً به صورت خودکار هنگام نصب یا به‌روزرسانی به اپلیکیشن اعطا می‌شوند و نیازی به تأیید صریح کاربر ندارند.

- **خطرناک (Dangerous):** مجوزهایی که به اطلاعات خصوصی کاربر (مانند مخاطبین، موقعیت مکانی، پیامک‌ها) دسترسی دارند یا می‌توانند بر عملکرد دستگاه یا سایر اپلیکیشن‌ها تأثیر بگذارند (مانند دسترسی به دوربین یا میکروفون). این مجوزها باید حتماً در زمان اجرا و به صورت صریح از کاربر درخواست شوند.

تحلیل الگوهای درخواست مجوز یکی از روش‌های مهم در تشخیص بدافزارهای اندرویدی است، زیرا بدافزارها اغلب مجوزهای خطرناک بیشتری نسبت به کاربرد ظاهری خود درخواست می‌کنند [۴].

^۱ Permission System

۲-۳-۲-۲ فایل APK

فرمت APK^۱ مخفف عبارت Android Package Kit است و فرمت فایل بسته‌بندی شده‌ای است که برای توزیع و نصب برنامه‌ها و میان‌افزارها در سیستم عامل اندروید استفاده می‌شود. فایل APK شامل تمام کدهای برنامه (مانند فایل‌های dex)، منابع (مانند تصاویر و لایه‌ها)، دارایی‌ها، گواهی‌نامه‌ها و فایل مانیفست (AndroidManifest.xml) است. این فایل بسیار شبیه به فرمت‌های بسته‌بندی دیگر مانند APPX در مایکروسافت ویندوز یا deb در سیستم‌های مبتنی بر دبیان (مانند اوبونتو) عمل می‌کند.

برای ساخت یک فایل APK، ابتدا برنامه اندروید با استفاده از ابزارهایی مانند اندروید استودیو کامپایل شده و سپس تمام اجزای آن در یک فایل فشرده با پسوند apk بسته‌بندی می‌شود. فایل‌های APK پایه و اساس برنامه‌های اندرویدی هستند و بخش اصلی اکوسیستم اندروید محسوب می‌شوند. کاربران می‌توانند فایل‌های APK را از منابع مختلف، از جمله فروشگاه رسمی گوگل پلی (Google Play) یا به صورت دستی (Sideloading) از وبسایت‌ها یا منابع دیگر، دانلود و نصب کنند. نصب دستی برنامه‌ها از منابع نامعتبر یکی از راه‌های اصلی ورود بدافزار به دستگاه‌های اندرویدی است.

علاوه بر سیستم عامل اندروید، فایل‌های APK را می‌توان با استفاده از شبیه‌سازها یا لایه‌های سازگاری در سایر سیستم‌عامل‌ها مانند ویندوز، مک‌اواس یا کروم‌اواس نیز اجرا، و با ابزارهای مهندسی معکوس، محتوای آن‌ها را استخراج، ویرایش یا تحلیل کرد.

۲-۳-۲-۳ سورس‌کد

سورس‌کد (Source Code) یا کد منبع برنامه، به مجموعه‌ای از دستورالعمل‌ها یا عبارات متنی اشاره دارد که توسط برنامه‌نویس به یک زبان برنامه‌نویسی خاص (مانند جاوا، کاتلین، ++C، پایتون) نوشته می‌شود تا یک برنامه کامپیوتری، عملکرد مورد نظر را پیاده‌سازی کند. سورس‌کد برای انسان قابل خواندن است و منطق، الگوریتم‌ها و ساختار برنامه را تعریف می‌کند.

برای اینکه کامپیوتر بتواند سورس‌کد را اجرا کند، باید ابتدا به زبان ماشین (کد باینری) ترجمه شود. این فرآیند توسط یک کامپایلر یا مفسر انجام می‌شود. در اکوسیستم اندروید، کدهای جاوا یا کاتلین معمولاً به بایت‌کد Dalvik (در نسخه‌های قدیمی‌تر) یا ART (Android Runtime) کامپایل می‌شوند که در فایل‌های dex درون فایل APK قرار می‌گیرند.

دسترسی به سورس‌کد یک برنامه امکان درک کامل عملکرد، اصلاح یا توسعه آن را فراهم می‌کند. در حوزه امنیت، تحلیل سورس‌کد (در صورت در دسترس بودن) یکی از روش‌های تحلیل ایستا برای یافتن آسیب‌پذیری‌ها یا کدهای مخرب است. با این حال، اکثر برنامه‌های تجاری یا بدافزارها به صورت کامپایل شده

^۱ Android Package Kit

و بدون سورس کد توزیع می‌شوند و تحلیل آن‌ها نیازمند مهندسی معکوس (مانند دیس‌اسمبل کردن کدهای باینری یا بایت‌کد) است.

۴-۲-۲ داده‌های چندوجهی در تشخیص بدافزار

داده‌های چندوجهی (Multi-Modal Data) به مجموعه‌ای از اطلاعات اشاره دارد که از منابع و قالب‌های متنوعی استخراج شده و برای تحلیل جامع‌تر یک پدیده، مانند تشخیص بدافزارهای اندرویدی، به کار می‌روند. در این پژوهش، مدل MAGNET با بهره‌گیری از سه نوع اصلی داده‌های چندوجهی، شامل داده‌های جدولی، گرافی و ترتیبی، طراحی شده است تا بتواند ویژگی‌های متنوع و مکمل اپلیکیشن‌های اندرویدی را به صورت یکپارچه پردازش کند. این رویکرد، برخلاف روش‌های سنتی که تنها به یک نوع داده (مثلاً فقط مجوزها یا فقط فراخوانی‌های API) وابسته‌اند، امکان درک عمیق‌تر رفتارهای مخرب را فراهم می‌سازد. در ادامه، هر یک از این انواع داده‌ها به طور جداگانه توضیح داده می‌شود.

۱-۴-۲-۲ داده‌های جدولی

داده‌های جدولی شامل ویژگی‌های ایستای اپلیکیشن‌های اندرویدی هستند که به صورت ساختارمند و معمولاً عددی یا دسته‌ای ارائه می‌شوند. این ویژگی‌ها می‌توانند شامل تعداد مجوزهای درخواست‌شده، اندازه فایل APK، نسخه SDK هدف، تعداد فعالیت‌ها (Activities)، سرویس‌ها (Services)، گیرنده‌های پخش (Broadcast Receivers)، ارائه‌دهندگان محتوا (Content Providers)، تعداد فراخوانی‌های API خاص، یا سایر متغیرهای استخراج‌شده از فایل AndroidManifest.xml یا کد کامپایل شده باشند. در این پژوهش، این داده‌ها با استفاده از کتابخانه PyTorch و به صورت اشیای تانسور (torch.Tensor) بارگذاری و پردازش می‌شوند. برای هر نمونه اپلیکیشن، یک بردار ویژگی با ابعاد مشخص تعریف می‌شود که نشان‌دهنده خصوصیات ایستای آن است. پیش‌پردازش این داده‌ها، مانند نرمال‌سازی (برای مقادیر عددی) یا کدگذاری وان‌هات (برای مقادیر دسته‌ای)، که با هدف بهبود عملکرد مدل انجام می‌شود، از مراحل کلیدی به شمار می‌رود. این نوع داده، پایه‌ای برای تحلیل‌های آماری و یادگیری الگوهای ساده در بدافزارها فراهم می‌کند (مثلاً بدافزارها ممکن است به طور متوسط مجوزهای بیشتری درخواست کنند).

۲-۴-۲-۲ داده‌های گرافی

داده‌های گرافی ساختارهایی هستند که روابط و تعاملات بین اجزای مختلف یک اپلیکیشن اندرویدی را مدل‌سازی می‌کنند. این داده‌ها می‌توانند نمایانگر گراف فراخوانی توابع (Call Graph)، گراف جریان کنترل (Control Flow Graph, CFG)، گراف وابستگی داده‌ها (Data Dependency Graph)، یا گراف روابط بین

اجزای برنامه (مانند ارتباط بین فعالیت‌ها از طریق Intents) باشند. گره‌ها (Nodes) در این گراف‌ها می‌توانند توابع، بلوک‌های کد، کلاس‌ها، مجوزها یا اجزای اندرویدی باشند و لبه‌ها (Edges) نشان‌دهنده روابطی مانند فراخوانی تابع، انتقال کنترل، جریان داده یا درخواست مجوز هستند. در این پژوهش، از کتابخانه PyTorch Geometric (torch_geometric) برای بارگذاری و پردازش این داده‌ها به صورت اشیای داده (Data) استفاده شده است. هر گراف شامل ماتریس همجواری (ساختار گراف) و ویژگی‌های گره‌ها (مانند نوع تابع یا بردار ویژگی‌های استخراج‌شده از کد) است. تحلیل گرافی به مدل اجازه می‌دهد تا الگوهای ساختاری پیچیده و وابستگی‌های پنهان بین اجزا را شناسایی کند (مانند شناسایی یک حلقه فراخوانی مشکوک یا یک خوشه از توابع مرتبط با سرقت اطلاعات)، که در تشخیص بدافزارهای پیچیده یا ناشناخته بسیار مؤثر است.

۲-۲-۴ داده‌های ترتیبی

داده‌های ترتیبی شامل توالی‌هایی از رویدادها یا مقادیر هستند که معمولاً نمایانگر رفتار زمانی یا ترتیب وقوع عملیات در اپلیکیشن‌ها هستند. در زمینه تشخیص بدافزار اندروید، این داده‌ها می‌توانند شامل توالی فراخوانی‌های API سیستمی در حین اجرای برنامه (استخراج‌شده از تحلیل پویا)، توالی رویدادهای سیستمی (مانند ارسال پیامک، اتصال به شبکه)، یا الگوهای زمانی استفاده از منابع (مانند مصرف CPU یا باتری) باشند. در این پژوهش، این داده‌ها با استفاده از تانسورهای LongTensor در PyTorch بارگذاری شده و برای هر نمونه یک یا چند توالی مشخص تعریف می‌شود. پیش‌پردازش این داده‌ها ممکن است شامل نگاشت هر رویداد یا API به یک شناسه عددی، پدینگ (Padding) توالی‌ها برای رسیدن به طول یکسان، و تبدیل به فرمت قابل پردازش توسط مدل‌های ترتیبی مانند RNN، LSTM یا ترنسفورمر باشد. استفاده از داده‌های ترتیبی به مدل امکان می‌دهد تا رفتار پویای اپلیکیشن‌ها را تحلیل کند و الگوهای زمانی مخرب، مانند توالی خاصی از فراخوانی‌ها که منجر به نشت داده می‌شود یا حملات دوره‌ای، را تشخیص دهد.

۲-۲-۴ اهمیت و یکپارچگی داده‌های چندوجهی

ترکیب این سه نوع داده در مدل MAGNET، با استفاده از مکانیزم‌های توجه پویا و تکنیک‌های همجوشی (Fusion)، به شناسایی دقیق‌تر و جامع‌تر بدافزارها کمک می‌کند. داده‌های جدولی اطلاعات کلی و ایستا، داده‌های گرافی روابط ساختاری پیچیده، و داده‌های ترتیبی رفتار پویا را ارائه می‌دهند که در کنار هم، تصویری کامل‌تر از اپلیکیشن را ترسیم می‌کنند. این رویکرد چندوجهی، به‌ویژه در مواجهه با بدافزارهای پیچیده و ناشناخته که ممکن است در یک وجه خاص (مثلاً فقط مجوزها) عادی به نظر برسند، مزیت رقابتی نسبت به روش‌های تک‌وجهی دارد و تعمیم‌پذیری مدل را افزایش می‌دهد [۹]. استخراج این داده‌ها از فایل‌های پردازش‌شده با توابع فرضی load_graph_data، load_processed_data و load_sequence_data

انجام شده و پیش‌پردازش آن‌ها با نرمال‌سازی، استانداردسازی و کدگذاری مناسب، تضمین‌کننده سازگاری با معماری‌های یادگیری عمیق مانند ترنسفورمر است.

۵-۲-۲ مدل‌های یادگیری عمیق


یادگیری عمیق، زیرشاخه‌ای از یادگیری ماشین، از شبکه‌های عصبی مصنوعی با چندین لایه (لایه‌های عمیق) برای یادگیری بازنمایی‌های پیچیده از داده‌ها استفاده می‌کند. در ادامه، چند معماری کلیدی که در تشخیص بدافزار کاربرد دارند، معرفی می‌شوند.

۱-۵-۲-۲ شبکه‌های عصبی کانولوشنی (CNN)

شبکه‌های عصبی کانولوشنی (Convolutional Neural Networks, CNNs) به طور خاص برای پردازش داده‌های با ساختار شبکه‌ای یا گریدمانند، مانند تصاویر، ماتریس‌های ویژگی یا داده‌های ترتیبی با پنجره لغزان، طراحی شده‌اند. این شبکه‌ها با بهره‌گیری از لایه‌های کانولوشنی که فیلترهای کوچکی را روی ورودی حرکت می‌دهند، قادرند ویژگی‌های محلی (مانند الگوهای خاص در بایت‌های کد، توالی‌های API، یا روابط بین مجوزها در یک ماتریس هم‌وقوعی) را به صورت سلسله‌مراتبی و خودکار استخراج کنند. لایه‌های تجمعی (Pooling) نیز با کاهش ابعاد مکانی داده و فشرده‌سازی اطلاعات، به افزایش پایداری نسبت به تغییرات جزئی و کاهش محاسبات کمک می‌کنند. در نهایت، لایه‌های کاملاً متصل (Fully Connected) از ویژگی‌های استخراج‌شده برای طبقه‌بندی نهایی (مثلاً بدافزار یا سالم) استفاده می‌کنند. در حوزه تشخیص بدافزار، شبکه‌های CNN می‌توانند برای تحلیل بایت‌های فایل اجرایی به عنوان تصویر، ماتریس‌های ویژگی‌های ایستا، یا توالی‌های رفتاری به کار روند و الگوهای مخرب را شناسایی نمایند [۸]. تحقیقات اخیر نشان داده است که شبکه‌های عصبی کانولوشنی می‌توانند دقت بالایی در تشخیص بدافزار ارائه دهند و ویژگی‌های مورد نیاز را مستقیماً از داده‌های خام یا نیمه‌پردازش‌شده یاد بگیرند [۱۰]. ساختار این شبکه‌ها معمولاً به صورت انتها به انتها (End-to-End) طراحی می‌شود و شامل پشته‌ای از لایه‌های کانولوشنی، فعال‌سازی (مانند ReLU)، و تجمعی است که به دنبال آن یک یا چند لایه کاملاً متصل قرار می‌گیرد. افزایش عمق شبکه (تعداد لایه‌ها) امکان استخراج ویژگی‌های انتزاعی‌تر و سطح بالاتر را فراهم می‌کند.

۲-۵-۲-۲ شبکه‌های عصبی بازگشتی و واحدهای حافظه بلند-کوتاه (RNN و LSTM)

شبکه‌های عصبی بازگشتی (Recurrent Neural Networks, RNNs) نوعی از شبکه‌های عصبی هستند که به طور ویژه برای پردازش داده‌های ترتیبی و زمانی طراحی شده‌اند. برخلاف شبکه‌های پیش‌خور



شکل ۱-۲ ساختار کلی یک شبکه عصبی کانولوشنی (CNN) ابتدا تصویر ورودی یا ماتریس ویژگی وارد شبکه می‌شود. در مرحله استخراج ویژگی، لایه‌های کانولوشنی و تجمعی به ترتیب ویژگی‌های محلی را استخراج و ابعاد داده را کاهش می‌دهند. سپس داده‌ها به یک بردار یک‌بعدی تبدیل شده (Flattening) و وارد لایه‌های کاملاً متصل می‌شوند تا فرایند طبقه‌بندی نهایی انجام گیرد. این ساختار باعث می‌شود شبکه بتواند به صورت خودکار و بدون نیاز به مهندسی ویژگی دستی، الگوهای پیچیده را شناسایی کند. برگرفته از [۱۰].

(Feedforward)، RNN ها دارای حلقه‌های بازگشتی در اتصالات خود هستند که به آن‌ها اجازه می‌دهد اطلاعات مربوط به مراحل قبلی توالی را در یک حالت پنهان (Hidden State) حفظ کرده و از آن برای پردازش مراحل بعدی استفاده کنند. این "حافظه" داخلی، RNN ها را برای کاربردهایی مانند تحلیل توالی فراخوانی‌های API، پردازش زبان طبیعی (مانند تحلیل کدهای اسمبلی یا توضیحات برنامه)، و تشخیص رفتارهای پویای اپلیکیشن‌ها که در طول زمان آشکار می‌شوند، مناسب می‌سازد.

یکی از چالش‌های اصلی RNN های ساده، مشکل محو یا انفجار گرادیان (Vanishing/Exploding Gradient) در هنگام یادگیری وابستگی‌های بلندمدت در توالی‌های طولانی است. برای رفع این مشکل، ساختارهای پیشرفته‌تری مانند واحد حافظه بلند-کوتاه (Long Short-Term Memory, LSTM) [۱۱] و واحد بازگشتی دروازه‌ای (Gated Recurrent Unit, GRU) [۱۲] معرفی شده‌اند. LSTM با بهره‌گیری از یک سلول حافظه (Memory Cell) و سه نوع گیت (گیت فراموشی، گیت ورودی و گیت خروجی)، امکان کنترل دقیق جریان اطلاعات را فراهم می‌کند. این گیت‌ها به شبکه اجازه می‌دهند تا تصمیم بگیرد کدام اطلاعات را در سلول حافظه نگه دارد، کدام را فراموش کند و کدام را به عنوان خروجی مرحله فعلی استفاده کند. این مکانیزم به LSTM ها کمک می‌کند تا اطلاعات مهم را در طول توالی‌های بسیار طولانی حفظ کرده و وابستگی‌های بلندمدت را به طور مؤثرتری مدل‌سازی کنند. GRU ساختار ساده‌تری نسبت به LSTM دارد (با دو گیت) اما عملکرد مشابهی در بسیاری از وظایف ارائه می‌دهد.

در این پژوهش، از LSTM (یا می‌توانست از GRU استفاده شود) برای تحلیل داده‌های ترتیبی، مانند توالی فراخوانی‌های API، به منظور شناسایی الگوهای رفتاری پویا در اپلیکیشن‌های اندرویدی استفاده شده است. این قابلیت، LSTM را به ابزاری قدرتمند برای تشخیص رفتارهای مخربی که در طول زمان و از طریق

دنباله‌ای از اقدامات رخ می‌دهند، تبدیل می‌کند.

۲-۵-۳ شبکه‌های عصبی گرافی (GNN)

شبکه‌های عصبی گرافی (Graph Neural Networks, GNNs) دسته‌ای از مدل‌های یادگیری عمیق هستند که برای پردازش داده‌هایی با ساختار گرافی (مانند شبکه‌های اجتماعی، مولکول‌های شیمیایی، یا گراف‌های فراخوانی توابع در نرم‌افزار) طراحی شده‌اند [۱۳]. داده‌های گرافی شامل مجموعه‌ای از گره‌ها (Nodes) و لبه‌ها (Edges) هستند که به ترتیب موجودیت‌ها و روابط بین آن‌ها را نشان می‌دهند. GNN‌ها قادرند هم ساختار (توپولوژی) گراف و هم ویژگی‌های گره‌ها و لبه‌ها را برای یادگیری بازنمایی‌های مفید به کار گیرند.

ایده اصلی در GNN‌ها، به‌روزرسانی بازنمایی (بردار ویژگی) هر گره بر اساس اطلاعات گره‌های همسایه آن است. این فرآیند معمولاً شامل دو مرحله اصلی است که در هر لایه GNN تکرار می‌شود:


۱. **تجمع (Aggregation):** جمع‌آوری اطلاعات (بازنمایی‌ها) از گره‌های همسایه. روش‌های مختلفی برای تجمع وجود دارد، مانند میانگین‌گیری، جمع یا حداکثرگیری.

۲. **به‌روزرسانی (Update):** ترکیب اطلاعات تجمع‌شده از همسایگان با اطلاعات خود گره (بازنمایی فعلی آن) برای تولید بازنمایی جدید گره. این کار معمولاً با استفاده از یک شبکه عصبی کوچک (مانند یک لایه خطی و یک تابع فعال‌سازی) انجام می‌شود.

با پشته کردن چندین لایه GNN، هر گره می‌تواند اطلاعات را از همسایگان دورتر نیز دریافت کند و بازنمایی‌های پیچیده‌تری که الگوهای ساختاری سطح بالاتر را در بر می‌گیرند، یاد گرفته شود. در این پژوهش، از GNN (به‌طور خاص، احتمالاً مدل‌هایی مانند Graph Convolutional Network (GCN) [۱۴] یا Graph Attention Network (GAT) [۱۵]) برای تحلیل داده‌های گرافی استخراج‌شده از اپلیکیشن‌ها (مانند گراف فراخوانی API) استفاده شده است. این داده‌ها با استفاده از کتابخانه torch_geometric به صورت اشیای Data بارگذاری و پردازش می‌شوند. GNN‌ها به مدل کمک می‌کنند تا ویژگی‌های ساختاری مهمی را که ممکن است نشان‌دهنده رفتار مخرب باشند (مانند الگوهای خاصی از تعامل بین توابع یا اجزا) استخراج کنند.

۲-۲-۶ ترنسفورمرها

۲-۲-۶-۱ معرفی ترنسفورمر و تحول در مدل‌های یادگیری عمیق نقطه عطف برجسته‌ای در تکامل معماری‌های یادگیری عمیق، معرفی مدل ترنسفورمر در مقاله "Attention Is All You Need" توسط



شکل ۲-۲ نمایی از یک مدل شبکه عصبی گرافی (GNN) ابتدا گراف ورودی (با ویژگی‌های اولیه گره‌ها و ساختار اتصالات) به مدل داده می‌شود. سپس در چندین بلوک GNN (لایه)، اطلاعات گره‌ها با جمع اطلاعات از همسایگان و به‌روزرسانی با استفاده از شبکه‌های عصبی کوچک، به‌طور مکرر پالایش می‌شود تا بازنمایی‌های غنی‌تری (گراف تبدیل‌شده) حاصل شود. در نهایت، این بازنمایی‌ها می‌توانند برای وظایف مختلف مانند طبقه‌بندی کل گراف (مثلاً بدافزار/سالم)، طبقه‌بندی گره‌ها (مثلاً شناسایی توابع مخرب) یا پیش‌بینی لبه‌ها استفاده شوند. برگرفته و بازطراحی شده بر اساس [۱۳].

al. et Vaswani [۱۶] بود که انقلابی در پردازش داده‌های ترتیبی، و بعدها انواع دیگر داده‌ها، به ارمغان آورد. این معماری، برخلاف مدل‌های بازگشتی (RNN/LSTM) که توالی‌ها را به صورت مرحله به مرحله پردازش می‌کردند و با مشکلاتی مانند وابستگی‌های بلندمدت و عدم امکان پردازش موازی مواجه بودند، صرفاً بر مکانیزم توجه (Attention Mechanism)، به‌ویژه توجه خودی (Self-Attention) و توجه چندسر (Multi-Head Attention)، تکیه می‌کند.

مکانیزم توجه به مدل اجازه می‌دهد تا هنگام پردازش یک عنصر در توالی (مثلاً یک کلمه در جمله یا یک فراخوانی API در یک دنباله)، به طور مستقیم به تمام عناصر دیگر توالی نگاه کرده و وزن اهمیتی متفاوتی به هر یک اختصاص دهد. این قابلیت، مدل‌سازی وابستگی‌های بلندمدت بین عناصر را بسیار کارآمدتر می‌کند. همچنین، از آنجایی که محاسبات توجه برای هر عنصر می‌تواند به صورت موازی انجام شود، ترنسفورمرها سرعت آموزش و استنتاج را به‌طور چشمگیری بهبود بخشیدند و امکان آموزش مدل‌های بسیار بزرگتر را فراهم کردند. معماری استاندارد ترنسفورمر شامل دو بخش اصلی است: کدگذار (Encoder) که ورودی را به یک دنباله از بازنمایی‌های پیوسته تبدیل می‌کند و گشاینده (Decoder) که این بازنمایی‌ها را برای تولید خروجی (مثلاً در ترجمه ماشینی یا تولید متن) به کار می‌برد. هر دوی این بخش‌ها از پشته‌هایی از لایه‌های توجه چندسر و شبکه‌های عصبی پیش‌خور (Feed-Forward Networks) تشکیل شده‌اند که با اتصالات باقیمانده (Residual Connections) و نرمال‌سازی لایه‌ای (Layer Normalization) ترکیب شده‌اند.

با ظهور ترنسفورمر، مدل‌های زبانی بزرگ (Large Language Models, LLMs) پیشرفته‌ای مانند BERT (که از پشته کدگذار ترنسفورمر استفاده می‌کند و برای درک زبان آموزش دیده) و GPT (که از پشته گشاینده ترنسفورمر بهره می‌برد و برای تولید زبان آموزش دیده) توسعه یافتند. این مدل‌ها با پیش‌آموزش روی حجم عظیمی از داده‌های متنی و سپس تنظیم دقیق (Fine-tuning) برای وظایف خاص، عملکردی استثنایی در طیف وسیعی از کاربردهای پردازش زبان طبیعی نشان دادند.

این پیشرفت‌ها، الهام‌بخش کاربرد ترنسفورمرها در حوزه‌های فراتر از زبان، از جمله بینایی کامپیوتر،

تحلیل داده‌های گرافی و همچنین امنیت سایبری و تشخیص بدافزار [۱۷] شد. توانایی ترنسفورمر در مدل‌سازی روابط پیچیده و بلندمدت و پردازش موازی، آن را به گزینه‌ای جذاب برای تحلیل داده‌های چندوجهی و پیچیده مرتبط با بدافزارها تبدیل کرد.


۷-۲-۲ ترنسفورمرها در مدل MAGNET

در این پژوهش، معماری ترنسفورمر به‌عنوان هسته اصلی مدل (MAGNET Multi-Modal Analysis) for Graph and Network Threat Detection) به کار گرفته شده است تا داده‌های چندوجهی شامل داده‌های جدولی (ویژگی‌های ایستا)، گرافی (روابط ساختاری) و ترتیبی (رفتار پویا) را به‌صورت یکپارچه تحلیل کند. ترنسفورمر در این مدل از مکانیزم توجه پویا برای یادگیری بازنمایی‌های غنی (Embeddings) از هر وجه داده و سپس تلفیق (Fusion) هوشمندانه این بازنمایی‌ها استفاده می‌کند.

به‌طور خاص، لایه‌های کدگذار ترنسفورمر می‌توانند برای پردازش ویژگی‌های استخراج‌شده از داده‌های جدولی (پس از تبدیل به دنباله‌ای از ویژگی‌ها یا استفاده از توکن‌های خاص) و داده‌های گرافی (با استفاده از تکنیک‌هایی مانند تبدیل گره‌ها به دنباله یا به‌کارگیری Graph Transformers) به کار روند. مکانیزم توجه چندسر به مدل اجازه می‌دهد تا روابط متقابل بین ویژگی‌های مختلف ایستا و ساختاری را کشف کند. همزمان، لایه‌های گشاینده ترنسفورمر (یا یک پشته کدگذار دیگر) می‌توانند برای مدل‌سازی توالی‌های ترتیبی (مانند فراخوانی‌های API) به کار گرفته شوند تا الگوهای زمانی مخرب شناسایی شوند.

ساختار ترنسفورمر در MAGNET احتمالاً شامل چندین بلوک کدگذار/گشاینده است که هر بلوک دارای یک لایه توجه چندسر و یک لایه تغذیه روبه‌جلو است. داده‌های ورودی از هر وجه ابتدا با استفاده از لایه‌های جاسازی (Embedding layers)، مانند nn.Embedding در PyTorch یا پروجکشن‌های خطی) به بردارهایی با ابعاد ثابت تبدیل می‌شوند. سپس، مکانیزم توجه خودی و احتمالاً توجه متقابل (Cross-Attention) بین وجه‌های مختلف، وزن‌های متفاوتی به هر عنصر داده تخصیص می‌دهد تا اهمیت نسبی آن را در پیش‌بینی نهایی برجسب (سالم یا مخرب) تعیین کند. این فرآیند با استفاده از نرمال‌سازی لایه‌ای و اتصالات باقیمانده برای پایداری و بهبود آموزش، بهینه می‌شود.

مزیت اصلی استفاده از ترنسفورمر در مدل MAGNET، توانایی آن در پردازش موازی داده‌های چندوجهی و درک روابط پیچیده و بلندمدت *درون* هر وجه و *بین* وجه‌های مختلف داده است. این ویژگی، به‌ویژه در شناسایی بدافزارهای پیچیده و ناشناخته که ممکن است از تکنیک‌های پنهان‌سازی پیشرفته استفاده کنند و نیازمند تحلیل جامع رفتار و ساختار اپلیکیشن‌ها هستند، بسیار مؤثر است. نتایج ادعا شده در متن (دقت ۹۷.۲۴ درصد و F1 Score ۰.۹۸۲۳) نشان می‌دهد که این رویکرد مبتنی بر ترنسفورمر و داده‌های چندوجهی، پتانسیل ارائه عملکردی برتر نسبت به مدل‌های سنتی یا تک‌وجهی را دارد.



شکل ۳-۲ ساختار کلی معماری ترنسفورمر شامل بخش کدگذار (Encoder) در سمت چپ و گشاینده (Decoder) در سمت راست. هر دو بخش از پشته‌ای از لایه‌های یکسان تشکیل شده‌اند که عمدتاً شامل مکانیزم توجه چندسر (Multi-Head Attention) و شبکه‌های عصبی پیش‌خور (Feed Forward) هستند. اتصالات باقیمانده (Add) و نرمال‌سازی لایه‌ای (Norm) نیز برای پایداری آموزش استفاده می‌شوند. گشاینده علاوه بر توجه خودی، از توجه متقابل (Cross-Attention) برای در نظر گرفتن خروجی کدگذار نیز بهره می‌برد. این معماری امکان پردازش موازی و مدل‌سازی وابستگی‌های بلندمدت را فراهم می‌کند. برگرفته و بازطراحی شده بر اساس [۱۶].

۸-۲-۲ ماشین بردار پشتیبان (SVM)

ماشین بردار پشتیبان (Support Vector Machine, SVM) یکی از الگوریتم‌های یادگیری نظارت‌شده قدرتمند و پرکاربرد است که عمدتاً برای مسائل طبقه‌بندی (Classification) و همچنین رگرسیون (Regression) استفاده می‌شود. ایده اصلی SVM در مسائل طبقه‌بندی دودویی، یافتن یک ابرصفحه (Hyperplane) بهینه در فضای ویژگی‌هاست که بتواند داده‌های مربوط به دو کلاس مختلف را به بهترین شکل ممکن از یکدیگر جدا کند.

”بهترین شکل ممکن” در SVM به معنای یافتن ابرصفحه‌ای است که بیشترین حاشیه (Margin) را با نزدیک‌ترین نقاط داده از هر دو کلاس داشته باشد. این نزدیک‌ترین نقاط، که روی مرز حاشیه قرار می‌گیرند، بردارهای پشتیبان (Support Vectors) نامیده می‌شوند، زیرا موقعیت ابرصفحه جداکننده تنها به این نقاط بستگی دارد. هدف، حداکثر کردن این حاشیه است، زیرا تئوری یادگیری آماری نشان می‌دهد که جداکننده‌ای با حاشیه بزرگتر، معمولاً خطای تعمیم کمتری دارد و عملکرد بهتری روی داده‌های دیده‌نشده خواهد داشت.

۸-۲-۲-۱ انواع SVM

• **SVM خطی (Linear SVM):** زمانی که داده‌ها به صورت خطی قابل تفکیک باشند (یعنی بتوان با یک خط مستقیم یا یک صفحه صاف آن‌ها را جدا کرد)، از SVM خطی استفاده می‌شود.

• **SVM غیرخطی (Non-linear SVM):** در بسیاری از مسائل دنیای واقعی، داده‌ها به صورت خطی قابل تفکیک نیستند. در این موارد، SVM از ترفند کرنل (Kernel Trick) استفاده می‌کند. ترفند کرنل به SVM اجازه می‌دهد تا داده‌ها را به یک فضای ویژگی با ابعاد بالاتر نگاشت کند که در آن، داده‌ها ممکن است به صورت خطی قابل تفکیک شوند. سپس SVM خطی در آن فضای جدید اعمال می‌شود. توابع کرنل رایج شامل کرنل چندجمله‌ای (Polynomial)، کرنل تابع پایه شعاعی (Radial Basis Function, RBF) یا گاوسی، و کرنل سیگموئید (Sigmoid) هستند.

۲-۲-۸-۰۰-۲ **کاربرد در تشخیص بدافزار** SVM به دلیل عملکرد خوب در فضاهای با ابعاد بالا و مقاومت نسبی در برابر بیش‌برازش (Overfitting)، به‌طور گسترده‌ای در تشخیص بدافزار اندروید، به‌ویژه با استفاده از ویژگی‌های استاتیک (مانند مجوزها، فراخوانی‌های API) یا ویژگی‌های پویا (مانند توالی‌های رفتاری) استفاده شده است [۳، ۱۸]. اغلب، ویژگی‌های استخراج‌شده از اپلیکیشن‌ها به عنوان ورودی به SVM داده می‌شوند تا مدل آموزش ببیند که آیا یک اپلیکیشن بدافزار است یا خیر.

۲-۲-۸-۰۰-۳ مزایا و معایب

• **مزایا:** کارایی بالا در فضاهای با ابعاد زیاد، مؤثر بودن در مواردی که تعداد ابعاد بیشتر از تعداد نمونه‌هاست، حافظه کارآمد (چون فقط از بردارهای پشتیبان استفاده می‌کند)، تطبیق‌پذیری با استفاده از کرنل‌های مختلف.

• **معایب:** عملکرد ضعیف در مجموعه داده‌های بسیار بزرگ (به دلیل پیچیدگی محاسباتی آموزش که می‌تواند بین $O(n^2)$ تا $O(n^3)$ باشد)، حساسیت به انتخاب تابع کرنل و پارامترهای آن (مانند پارامتر C یا هزینه خطا و پارامتر گاما در کرنل RBF)، عدم ارائه مستقیم احتمالات تعلق به کلاس (اگرچه روش‌هایی برای تخمین آن وجود دارد).

اگرچه مدل‌های یادگیری عمیق مانند CNN و ترنسفورمرها در سال‌های اخیر توجه بیشتری را به خود جلب کرده‌اند، SVM همچنان یک ابزار قدرتمند و یک معیار (Baseline) مهم در حوزه تشخیص بدافزار محسوب می‌شود.

۳-۲ تکنیک‌های آموزشی و ارزیابی

در این بخش، تکنیک‌های کلیدی مورد استفاده برای آموزش مدل MAGNET و ارزیابی عملکرد آن تشریح می‌شود. این تکنیک‌ها برای اطمینان از قابلیت اطمینان، کارایی و تعمیم‌پذیری مدل ضروری هستند.

۱-۳-۲ اعتبارسنجی متقاطع (Cross-Validation)

اعتبارسنجی متقاطع (Cross-Validation) یک تکنیک آماری برای ارزیابی عملکرد مدل‌های یادگیری ماشین و تخمین میزان تعمیم‌پذیری آن‌ها به داده‌های جدید و مستقل است. این روش به کاهش واریانس تخمین عملکرد کمک کرده و از بیش‌برازش (Overfitting) بر روی یک تقسیم خاص از داده‌ها به مجموعه‌های آموزشی و آزمایشی جلوگیری می‌کند.

رایج‌ترین نوع اعتبارسنجی متقاطع، اعتبارسنجی تایی-k (k-fold Cross-Validation) است. در این روش:

۱. مجموعه داده اصلی به صورت تصادفی به k زیرمجموعه (یا "تا") با اندازه تقریباً مساوی تقسیم می‌شود.

۲. فرآیند آموزش و ارزیابی k بار تکرار می‌شود.

۳. در هر تکرار (i از ۱ تا k)، از $k-1$ زیرمجموعه برای آموزش مدل استفاده می‌شود و از زیرمجموعه باقی‌مانده (تا i -ام) به عنوان مجموعه اعتبارسنجی (Validation Set) برای ارزیابی مدل استفاده می‌شود.

۴. نتایج ارزیابی (مانند دقت، F1 Score) از هر k تکرار جمع‌آوری می‌شود.

۵. میانگین (و گاهی انحراف معیار) این نتایج به عنوان تخمین نهایی عملکرد مدل گزارش می‌شود.

در این پژوهش، از اعتبارسنجی ۵-تایی (5-fold Cross-Validation) استفاده شده است ($k = 5$). این بدان معناست که داده‌ها به پنج بخش تقسیم شده و مدل پنج بار آموزش و ارزیابی می‌شود، هر بار با یک بخش متفاوت به عنوان داده اعتبارسنجی. این رویکرد نسبت به تقسیم ساده آموزشی/آزمایشی، تخمین پایدارتر و قابل اعتمادتری از عملکرد مدل ارائه می‌دهد، زیرا از تمام داده‌ها هم برای آموزش و هم برای ارزیابی استفاده می‌شود. در پیاده‌سازی کد، این فرآیند می‌تواند با استفاده از توابعی مانند KFold یا StratifiedKFold از کتابخانه scikit-learn و اجرای حلقه آموزش و ارزیابی (مانند تابع `train_and_evaluate_magnet`) در هر تقسیم انجام شود.

۲-۳-۲ مدیریت اورفیتینگ و آندرفیتینگ

دو چالش اساسی در آموزش مدل‌های یادگیری ماشین، به‌ویژه مدل‌های یادگیری عمیق با ظرفیت بالا، بیش‌برازش (Overfitting) و کم‌برازش (Underfitting) هستند.

- **کم‌برازش (Underfitting):** زمانی رخ می‌دهد که مدل به اندازه کافی پیچیده نیست یا به اندازه کافی آموزش ندیده است تا الگوهای اساسی موجود در داده‌های آموزشی را یاد بگیرد. در نتیجه، مدل هم بر روی داده‌های آموزشی و هم بر روی داده‌های جدید عملکرد ضعیفی دارد. برای مقابله با کم‌برازش، می‌توان پیچیدگی مدل را افزایش داد (مثلاً با افزودن لایه‌ها یا نورون‌ها)، ویژگی‌های بهتری مهندسی کرد، یا زمان آموزش را افزایش داد. در مدل MAGNET، تنظیم مناسب تعداد لایه‌ها (num_layers) و ابعاد نهان (embedding_dim) می‌تواند به جلوگیری از کم‌برازش کمک کند.

- **بیش‌برازش (Overfitting):** زمانی رخ می‌دهد که مدل بیش از حد به داده‌های آموزشی خاص، از جمله نویز و جزئیات تصادفی آن، وابسته می‌شود. در نتیجه، مدل بر روی داده‌های آموزشی عملکرد بسیار خوبی دارد، اما توانایی تعمیم به داده‌های جدید و دیده‌نشده را از دست می‌دهد و بر روی آن‌ها عملکرد ضعیفی نشان می‌دهد. برای مقابله با بیش‌برازش، از تکنیک‌های تنظیم‌گری (Regularization) استفاده می‌شود. در این پژوهش، از تکنیک‌های زیر استفاده شده است:

– **Dropout:** در هر مرحله آموزش، به طور تصادفی برخی از نورون‌ها (و اتصالات آن‌ها) را با احتمال مشخصی (در اینجا با نرخ ۰.۲) غیرفعال می‌کند. این کار باعث می‌شود شبکه به یک مسیر یا ویژگی خاص بیش از حد وابسته نشود و مدل مقاوم‌تری یاد بگیرد.

– **توقف زودهنگام (Early Stopping):** عملکرد مدل بر روی یک مجموعه اعتبارسنجی جداگانه در طول آموزش نظارت می‌شود. اگر عملکرد مدل روی مجموعه اعتبارسنجی برای تعداد مشخصی از دوره‌ها (Epochs) بهبود نیابد (در اینجا با صبر ۳ دوره)، آموزش متوقف می‌شود، حتی اگر عملکرد روی مجموعه آموزشی همچنان در حال بهبود باشد. این کار از ادامه آموزش و ورود مدل به فاز بیش‌برازش جلوگیری می‌کند.

– **تنظیم‌گری L_2 (Weight Decay):** (هرچند به صراحت در بخش بیش‌برازش ذکر نشده، اما در بخش بهینه‌سازی Adam با $\text{weight_decay}=0.01$ اشاره شده است). این روش با افزودن یک جمله جریمه به تابع هزینه که متناسب با مجذور اندازه وزن‌های مدل است، از بزرگ شدن بیش از حد وزن‌ها جلوگیری می‌کند و به مدل ساده‌تر و با تعمیم‌پذیری بهتر منجر می‌شود.

تحلیل نمودارهای تابع هزینه و معیارهای ارزیابی بر روی داده‌های آموزشی و اعتبارسنجی در طول زمان آموزش، ابزار مهمی برای تشخیص و مدیریت این دو پدیده است.

۲-۳-۳ روش‌های بهینه‌سازی

بهینه‌سازی فرآیند تنظیم پارامترهای مدل (مانند وزن‌ها و بایاس‌ها در شبکه‌های عصبی) به منظور کمینه کردن تابع هزینه (Loss Function) است. انتخاب الگوریتم بهینه‌سازی مناسب و تنظیم ابرپارامترهای (Hyperparameters) آن نقش کلیدی در سرعت همگرایی و کیفیت نهایی مدل دارد.

۲-۳-۳-۱ الگوریتم Adam

الگوریتم Adam (Adaptive Moment Estimation) یکی از محبوب‌ترین و کارآمدترین الگوریتم‌های بهینه‌سازی مبتنی بر گرادیان نزولی تصادفی (Stochastic Gradient Descent, SGD) است که برای آموزش شبکه‌های عصبی عمیق استفاده می‌شود. Adam نرخ یادگیری (Learning Rate) را برای هر پارامتر به صورت تطبیقی تنظیم می‌کند. این کار را با استفاده از تخمین‌های مرتبه اول (میانگین یا مومنتوم) و مرتبه دوم (واریانس غیرمرکزی) گرادیان‌ها انجام می‌دهد. به عبارت دیگر، Adam مزایای دو الگوریتم دیگر، یعنی AdaGrad (که نرخ یادگیری را بر اساس فراوانی به‌روزرسانی پارامتر تنظیم می‌کند) و RMSProp (که از میانگین متحرک نمایی مجذور گرادیان‌ها استفاده می‌کند) را با هم ترکیب می‌کند و همچنین از مومنتوم برای هموارسازی مسیر گرادیان و تسریع همگرایی بهره می‌برد. در این پژوهش، Adam با نرخ یادگیری پیش‌فرض (معمولاً ۰.۰۰۱) و ضریب تنظیم‌گری L2 (weight_decay) برابر با ۰.۰۱ در تابع train_and_evaluate_magnet برای به‌روزرسانی وزن‌های مدل MAGNET به کار رفته است. Adam به دلیل سرعت همگرایی بالا، نیاز کمتر به تنظیم دقیق نرخ یادگیری اولیه، و عملکرد خوب در مسائل با گرادیان‌های پراکنده یا نویزی، انتخاب مناسبی برای آموزش مدل‌های پیچیده مانند ترنسفورمر و GNN بر روی داده‌های چندوجهی بوده است.

۲-۳-۳-۲ الگوریتم PIRATES

الگوریتم PIRATES^۱ یکی از روش‌های نوین بهینه‌سازی الهام‌گرفته از طبیعت است که با الهام از رفتار جمعی دزدان دریایی در جستجوی گنج طراحی شده است. این الگوریتم با الهام از مطالعات [۱۹] در زمینه بهینه‌سازی و کاربردهای یادگیری تقویتی [۲۰]، و همچنین با استفاده از مفاهیم بازی دزدان دریایی [۲۱]، طراحی شده است. در این الگوریتم، هر راه‌حل بالقوه به عنوان یک «کشتی» در فضای جستجو مدل می‌شود

^۱ Pirate-Inspired Robust Adaptive Trajectory Exploration Strategy

و مجموعه‌ای از کشتی‌ها (جمعیت) به طور موازی و با استفاده از اطلاعات فردی (تجربیات گذشته)، جمعی (اطلاعات بهترین اعضا)، و تعاملات خاص (مانند نبرد و طوفان)، به سمت نقاط بهینه حرکت می‌کنند. این الگوریتم با ترکیب ایده‌هایی از الگوریتم‌های ازدحامی (مانند PSO و تکاملی، سعی در افزایش پایداری، سرعت همگرایی و جلوگیری از گیر افتادن در بهینه‌های محلی دارد. اجزای کلیدی این الگوریتم عبارت‌اند از:

- **کشتی‌ها (Ships):** هر کشتی نمایانگر یک نقطه در فضای جستجو است و موقعیت و سرعت مخصوص به خود را دارد.

- **رهبر (Leader):** کشتی با بهترین عملکرد (کمترین مقدار تابع هدف) در هر تکرار به عنوان رهبر انتخاب می‌شود و سایر کشتی‌ها از آن پیروی می‌کنند.

- **نقشه جمعی و خصوصی:** هر کشتی علاوه بر بهترین موقعیت شخصی، از نقشه‌ای جمعی (شامل بهترین موقعیت‌های سایر کشتی‌ها) نیز بهره می‌برد.

- **کشتی‌های برتر (Top Ships):** تعدادی از بهترین کشتی‌ها به عنوان مرجع برای سایر اعضا عمل می‌کنند.

- **مکانیزم‌های تنوع‌بخش:** الگوریتم با استفاده از نبرد بین کشتی‌های برتر و وقوع طوفان‌های تصادفی، از همگرایی زودهنگام و گیر افتادن در بهینه‌های محلی جلوگیری می‌کند.

الگوریتم PIRATES با بهره‌گیری از چندین منبع اطلاعاتی و تنظیم پویا، قادر است به سرعت به نقاط بهینه همگرا شود و در عین حال تنوع جمعیت را حفظ کند. این ویژگی‌ها، PIRATES را به گزینه‌ای مناسب برای بهینه‌سازی مسائل پیچیده، از جمله تنظیم خودکار هایپرپارامترهای مدل‌های یادگیری عمیق و چندوجهی، تبدیل کرده است. در پژوهش حاضر، از این الگوریتم برای جستجوی بهینه پارامترهای مدل استفاده شده است.

استفاده از الگوریتم‌های بهینه‌سازی الهام‌گرفته از طبیعت، به ویژه PIRATES، در سال‌های اخیر به عنوان رویکردی مؤثر برای حل مسائل بهینه‌سازی غیرخطی و پیچیده در حوزه‌های مختلف، از جمله امنیت سایبری و یادگیری ماشین، مطرح شده است. در این پژوهش، PIRATES به عنوان یکی از ابزارهای کلیدی برای تنظیم بهینه پارامترهای مدل چندوجهی مبتنی بر ترنسفورمر و شبکه‌های عصبی گرافی به کار رفته است.

۲-۳-۳-۳ الگوریتم Optuna

Optuna [۲۲] یک چارچوب (Framework) نرم‌افزاری متن‌باز و قدرتمند برای بهینه‌سازی خودکار

هایپرپارامترها است. Optuna از الگوریتم‌های جستجوی متنوعی پشتیبانی می‌کند، از جمله جستجوی تصادفی (Random Search)، جستجوی شبکه‌ای (Grid Search)، و الگوریتم‌های پیشرفته‌تر مبتنی بر مدل مانند Tree-structured Parzen Estimator (TPE) که نوعی بهینه‌سازی بیزی است. یکی از ویژگی‌های کلیدی Optuna، قابلیت هرس (Pruning) آزمایش‌های ناموفق است. با استفاده از الگوریتم‌های هرس (مانند Median Pruning یا Successive Halving)، Optuna می‌تواند آزمایش‌هایی را که در مراحل اولیه عملکرد ضعیفی دارند، متوقف کرده و منابع محاسباتی را بر روی آزمایش‌های امیدوارکننده‌تر متمرکز کند.

در این پژوهش، ادعا شده که از Optuna برای تنظیم پارامترهایی مانند نرخ Dropout (که مقدار بهینه ۲۰٪ یافت شده) و ابعاد نهان (embedding_dim) استفاده شده است. این فرآیند معمولاً شامل تعریف یک تابع هدف (مانند تابع train_and_evaluate_magnet که یک معیار عملکرد مثل F1 Score یا دقت را برمی‌گرداند) و مشخص کردن فضای جستجو برای هر هایپرپارامتر است. سپس Optuna با اجرای مکرر تابع هدف با مقادیر مختلف هایپرپارامترها (که با استفاده از نمونه‌برداری تطبیقی انتخاب می‌شوند)، به تدریج به سمت یافتن ترکیب بهینه حرکت می‌کند. استفاده از Optuna می‌تواند فرآیند زمان‌بر و خسته‌کننده تنظیم دستی هایپرپارامترها را خودکار کرده و به یافتن مدل‌هایی با عملکرد بهتر کمک کند.

۴-۳-۲ معیارهای ارزیابی عملکرد

برای ارزیابی کمی و کیفی عملکرد مدل طبقه‌بندی MAGNET در تشخیص بدافزارهای اندرویدی، از معیارهای استاندارد مختلفی استفاده شده است. انتخاب معیار مناسب به ماهیت مسئله و توزیع کلاس‌ها در مجموعه داده بستگی دارد.

۱-۴-۳-۲ دقت (Accuracy)

دقت (Accuracy) ساده‌ترین و رایج‌ترین معیار ارزیابی است که نسبت کل نمونه‌هایی که به درستی توسط مدل طبقه‌بندی شده‌اند (چه مثبت و چه منفی) به تعداد کل نمونه‌ها را اندازه‌گیری می‌کند:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

که در آن:

- TP (True Positive): تعداد نمونه‌های بدافزار که به درستی بدافزار تشخیص داده شده‌اند.
- TN (True Negative): تعداد نمونه‌های سالم که به درستی سالم تشخیص داده شده‌اند.

- FP (False Positive): تعداد نمونه‌های سالم که به اشتباه بدافزار تشخیص داده شده‌اند (خطای نوع اول).

- FN (False Negative): تعداد نمونه‌های بدافزار که به اشتباه سالم تشخیص داده شده‌اند (خطای نوع دوم).

در این پژوهش، دقت مدل MAGNET در تست نهایی ۲۴.۹۷ درصد گزارش شده است. دقت معیار خوبی است زمانی که کلاس‌ها تقریباً متوازن باشند. با این حال، در مجموعه‌های داده نامتوازن (مثلاً اگر تعداد نمونه‌های سالم بسیار بیشتر از بدافزارها باشد)، دقت بالا ممکن است گمراه‌کننده باشد.

۲-۳-۴ Score F1

امتیاز F1 (F1 Score) میانگین هارمونیک دو معیار دیگر، یعنی دقت (Precision) و یادآوری (Recall) است و به ویژه در مسائل با کلاس‌های نامتوازن مفید است.

- **دقت (Precision):** نسبت نمونه‌هایی که به درستی مثبت پیش‌بینی شده‌اند به کل نمونه‌هایی که مثبت پیش‌بینی شده‌اند. این معیار نشان می‌دهد که چقدر می‌توان به پیش‌بینی‌های مثبت مدل اعتماد کرد.

$$\text{Precision} = \frac{TP}{TP + FP}$$

- **یادآوری (Recall) یا حساسیت (Sensitivity):** یا نرخ مثبت واقعی (TPR): نسبت نمونه‌هایی که به درستی مثبت پیش‌بینی شده‌اند به کل نمونه‌های واقعاً مثبت. این معیار نشان می‌دهد که مدل چه کسری از نمونه‌های مثبت واقعی را توانسته شناسایی کند.

$$\text{Recall} = \frac{TP}{TP + FN}$$

امتیاز F1 به صورت زیر محاسبه می‌شود:

$$\text{Score F1} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} = \frac{2 \times TP}{2 \times TP + FP + FN}$$

امتیاز F1 تعادلی بین دقت و یادآوری برقرار می‌کند و مقدار بالای آن نشان می‌دهد که مدل هم در کاهش هشدارهای کاذب (FP بالا باعث کاهش Precision می‌شود) و هم در شناسایی نمونه‌های مثبت واقعی (FN بالا باعث کاهش Recall می‌شود) موفق بوده است. در این پژوهش، مقدار F1 Score ۰.۹۸۲۳ در بهترین

حالت به دست آمده که نشان‌دهنده عملکرد بسیار خوب مدل در هر دو جنبه است. این معیار معمولاً برای ارزیابی عملکرد در تشخیص بدافزار ارجحیت دارد، زیرا هزینه تشخیص نادرست (FN یا FP) می‌تواند بالا باشد.

۲-۳-۴-۳ AUC (Area Under the ROC Curve)

منحنی مشخصه عملکرد گیرنده (Receiver Operating Characteristic, ROC) نموداری است که نرخ مثبت واقعی (True Positive Rate, TPR یا همان Recall) را در مقابل نرخ مثبت کاذب (False Positive Rate, FPR) در آستانه‌های طبقه‌بندی مختلف رسم می‌کند.

$$FPR = \frac{FP}{FP + TN}$$

مساحت زیر این منحنی (Area Under the Curve, AUC) یک معیار واحد است که توانایی کلی مدل در تمایز بین کلاس‌های مثبت و منفی را در تمام آستانه‌های ممکن اندازه‌گیری می‌کند. مقدار AUC بین ۰ و ۱ متغیر است.

• $AUC = 1$: طبقه‌بندی کامل و بی‌نقص.

• $AUC = 0.5$: عملکرد تصادفی (مانند پرتاب سکه).

• $AUC < 0.5$: عملکرد بدتر از تصادفی.

AUC یک معیار مفید است زیرا نسبت به تغییرات آستانه طبقه‌بندی و همچنین نسبت به عدم توازن کلاس‌ها (تا حدی) مقاوم است. هرچند مقدار دقیق AUC در متن گزارش نشده، اما با توجه به F1 Score بالا (۰.۹۸۲۳)، انتظار می‌رود مقدار AUC نیز بسیار بالا و نزدیک به ۱ (احتمالاً حدود ۰.۹۸ یا بیشتر) باشد، که نشان‌دهنده قدرت تمایز عالی مدل MAGNET است.

۲-۳-۴-۳-۱ **جمع‌بندی ارزیابی** استفاده ترکیبی از این معیارها (دقت، F1 Score، AUC) به همراه اعتبارسنجی متقاطع، تصویری جامع و قابل اعتماد از عملکرد مدل MAGNET ارائه می‌دهد و امکان مقایسه معنادار آن با سایر روش‌ها را فراهم می‌کند. مدیریت دقیق بیش‌برازش و کم‌برازش و استفاده از روش‌های بهینه‌سازی مناسب نیز به دستیابی به این نتایج کمک کرده‌اند.

۴-۲ مروری بر مطالعات پیشین

در این بخش، پژوهش‌های پیشین در حوزه تشخیص بدافزارهای اندرویدی با تمرکز بر رویکردهای اصلی تحلیل ایستا و پویا مرور می‌شوند. همچنین، به تاریخچه مختصری از تلاش‌ها در این زمینه اشاره می‌شود.

۱-۴-۲ روش‌های تحلیل ایستا

روش‌های تحلیل ایستا (Static Analysis) به بررسی و تحلیل کد و ساختار اپلیکیشن‌های اندرویدی بدون نیاز به اجرای آن‌ها می‌پردازند. این روش‌ها معمولاً سریع‌تر از تحلیل پویا هستند و می‌توانند پوشش کاملی از کد برنامه را فراهم کنند. ویژگی‌های استخراج‌شده از تحلیل ایستا اغلب به عنوان ورودی برای مدل‌های یادگیری ماشین استفاده می‌شوند [۳].

۱-۱-۴-۲ تحلیل ویژگی‌های مبتنی بر مانیفست و متاداده

فایل AndroidManifest.xml حاوی اطلاعات مهمی درباره ساختار و نیازمندی‌های اپلیکیشن است.

- **تحلیل مجوزها (Permissions):** یکی از پرکاربردترین روش‌های ایستا، تحلیل الگوهای مجوزهای درخواست‌شده توسط اپلیکیشن است. بدافزارها اغلب مجوزهای خطرناک و غیرضروری بیشتری نسبت به کاربرد ظاهری خود درخواست می‌کنند. پژوهش‌های متعددی مانند Drebin [۴] نشان داده‌اند که ترکیب مجوزها با سایر ویژگی‌های ایستا می‌تواند در تشخیص بدافزار مؤثر باشد. مدل‌های یادگیری ماشین مانند SVM، درخت تصمیم و بیز ساده اغلب برای طبقه‌بندی بر اساس این ویژگی‌ها استفاده شده‌اند.

- **اجزای برنامه (Components):** تعداد و نوع اجزای تعریف‌شده در مانیفست (مانند Activities, Services, Receivers, Providers) و همچنین فیلترهای Intent مرتبط با آن‌ها نیز می‌تواند اطلاعات مفیدی در اختیار قرار دهد.

۲-۱-۴-۲ تحلیل کد (Code Analysis)

این روش‌ها به بررسی خود کد برنامه (بایت‌کد Dalvik/ART یا کد Native) می‌پردازند.

- **تحلیل فراخوانی‌های API:** شناسایی و تحلیل فراخوانی‌های API حساس (مانند API‌های مربوط به ارسال پیامک، دسترسی به موقعیت مکانی، یا استفاده از توابع رمزنگاری) یکی دیگر از رویکردهای رایج است. الگوها یا توالی‌های خاصی از فراخوانی‌های API می‌توانند نشان‌دهنده رفتار مخرب باشند.

این ویژگی‌ها می‌توانند به صورت باینری (وجود یا عدم وجود فراخوانی) یا به صورت فراوانی استفاده شوند.

- **تحلیل جریان داده و کنترل (Data/Control Flow Analysis):** روش‌های پیشرفته‌تر تحلیل ایستا، گراف جریان کنترل (CFG) یا گراف جریان داده (DFG) برنامه را ساخته و تحلیل می‌کنند تا مسیرهای اجرای بالقوه و نحوه انتشار داده‌های حساس را ردیابی کنند. تکنیک‌هایی مانند Taint Analysis ایستا می‌توانند برای شناسایی نشت اطلاعات خصوصی به کار روند.

- **ویژگی‌های مبتنی بر Opcode:** تحلیل توالی‌ها یا فراوانی کدهای عملیاتی (Opcodes) در بایت‌کد نیز به عنوان ویژگی برای مدل‌های یادگیری ماشین استفاده شده است.

۳-۱-۴-۲ تحلیل ایستای ساختاری

- **گراف فراخوانی (Call Graph):** ساخت و تحلیل گراف فراخوانی توابع، که روابط فراخوانی بین متدهای مختلف برنامه را نشان می‌دهد، می‌تواند به شناسایی الگوهای ساختاری مرتبط با بدافزار کمک کند. شبکه‌های عصبی گرافی (GNN) برای تحلیل این گراف‌ها مناسب هستند.

۱-۳-۱-۴-۲ محدودیت‌های تحلیل ایستا با وجود مزایا، تحلیل ایستا با چالش‌هایی نیز روبروست:

- **ابهام‌سازی (Obfuscation):** بدافزارها اغلب از تکنیک‌های ابهام‌سازی کد (مانند تغییر نام متغیرها و توابع، درج کدهای زائد، رمزنگاری رشته‌ها) برای دشوار کردن تحلیل ایستا استفاده می‌کنند.

- **بارگذاری پویای کد (Dynamic Code Loading):** برخی بدافزارها بخش‌هایی از کد مخرب خود را در زمان اجرا از منابع خارجی دانلود و اجرا می‌کنند که این بخش‌ها در تحلیل ایستا قابل مشاهده نیستند.

- **کد Native:** تحلیل کدهای نوشته شده به زبان‌های Native (مانند C/C++) که از طریق JNI فراخوانی می‌شوند، پیچیده‌تر از تحلیل بایت‌کد جاوا/کاتلین است.

۲-۴-۲ روش‌های تحلیل پویا

روش‌های تحلیل پویا (Dynamic Analysis) یا آنالیز رفتاری، اپلیکیشن را در یک محیط کنترل‌شده (مانند شبیه‌ساز، دستگاه واقعی یا جعبه شنی Sandbox) اجرا کرده و رفتار آن را در زمان اجرا مشاهده و ثبت می‌کنند. این روش‌ها می‌توانند بر محدودیت‌های تحلیل ایستا در مواجهه با ابهام‌سازی و بارگذاری پویای کد غلبه کنند، زیرا رفتار واقعی برنامه را بررسی می‌کنند [۳].

۲-۴-۱ مانیتورینگ رفتار سیستم

این روش‌ها فعالیت‌های اپلیکیشن در سطح سیستم عامل را رصد می‌کنند.

- **ردیابی فراخوانی‌های سیستمی (System Call Tracing):** ثبت و تحلیل توالی فراخوانی‌های سیستمی که برنامه انجام می‌دهد. الگوهای خاصی از این فراخوانی‌ها می‌توانند نشان‌دهنده فعالیت مخرب باشند.

- **تحلیل Taint پویا (Dynamic Taint Analysis):** ابزارهایی مانند TaintDroid داده‌های حساس (منابع Taint) را مشخص کرده و نحوه انتشار آن‌ها در طول اجرای برنامه را ردیابی می‌کنند تا نشت اطلاعات به مقاصد غیرمجاز (سینک‌های Taint) را شناسایی کنند.

- **مانیتورینگ تغییرات فایل سیستم و رجیستری (در محیط ویندوز):** ثبت هرگونه ایجاد، حذف یا تغییر فایل‌ها یا تنظیمات سیستمی.

۲-۴-۲ تحلیل شبکه

بسیاری از بدافزارها برای ارتباط با سرور فرماندهی و کنترل (C&C)، ارسال داده‌های سرقت‌شده یا دانلود کدهای مخرب بیشتر، از شبکه استفاده می‌کنند. تحلیل ترافیک شبکه اپلیکیشن می‌تواند الگوهای مشکوکی مانند اتصال به IPها یا دامنه‌های شناخته‌شده مخرب، استفاده از پروتکل‌های غیرمعمول، یا حجم بالای ترافیک خروجی را آشکار کند.

۲-۴-۳ بررسی مصرف منابع

الگوهای غیرعادی در مصرف منابع سیستم مانند CPU، حافظه، باتری یا پهنای باند شبکه نیز می‌تواند نشانه‌ای از فعالیت بدافزاری باشد (مثلاً استخراج رمزارز یا اجرای حملات DoS).

- **۲-۴-۳-۱ ابزارها و محیط‌های تحلیل پویا** ابزارها و پلتفرم‌های مختلفی برای تحلیل پویای بدافزارهای اندرویدی توسعه یافته‌اند، از جمله DroidBox، AndroPyTool، Mobile Sandbox و پلتفرم‌های تجاری مانند Joe Sandbox Mobile. این ابزارها معمولاً اجرای برنامه را در یک شبیه‌ساز یا دستگاه روت‌شده خودکار کرده و گزارش جامعی از رفتارهای مشاهده‌شده تولید می‌کنند.

۲-۴-۳-۲ محدودیت‌های تحلیل پویا

- پوشش محدود کد (Limited Code Coverage): تحلیل پویا تنها مسیرهای اجرایی را بررسی می‌کند که در طول اجرای خاص فعال شده‌اند. بدافزارها ممکن است شامل کدهای مخربی باشند که تنها تحت شرایط خاصی (مثلاً در تاریخ معین یا با دریافت دستور خاص) فعال می‌شوند و در طول تحلیل مشاهده نشوند.
- زمان‌بر بودن: اجرای هر اپلیکیشن و ثبت رفتارهای آن می‌تواند زمان‌بر باشد، که تحلیل مجموعه داده‌های بزرگ را دشوار می‌کند.
- تشخیص محیط تحلیل (Environment Detection): بدافزارهای پیشرفته ممکن است تلاش کنند تا تشخیص دهند که آیا در یک محیط تحلیل (مانند شبیه‌ساز یا جعبه شنی) اجرا می‌شوند یا خیر و در این صورت، رفتار مخرب خود را پنهان کنند.
- نیاز به منابع: نیاز به محیط‌های اجرایی ایزوله و ابزارهای مانیتورینگ دارد.

۴-۲-۴ روش‌های ترکیبی (Hybrid Approaches)

برای بهره‌مندی از مزایای هر دو روش و غلبه بر محدودیت‌های آن‌ها، بسیاری از سیستم‌های تشخیص بدافزار مدرن از رویکردهای ترکیبی استفاده می‌کنند که ویژگی‌های استخراج‌شده از تحلیل ایستا و پویا را با هم ترکیب کرده و به عنوان ورودی به مدل‌های یادگیری ماشین یا یادگیری عمیق می‌دهند [۲]. مدل MAGNET در این پژوهش نیز با استفاده از داده‌های چندوجهی (که می‌توانند شامل ویژگی‌های ایستا و پویا باشند) در این دسته قرار می‌گیرد.

۳-۴-۲ کارهای پیشین و تاریخچه مختصر

تلاش‌ها برای شناسایی و مقابله با بدافزارها تاریخچه‌ای طولانی دارد. از اولین برنامه‌های آنتی‌ویروس مانند Flushot Plus (۱۹۸۷) و اسکنر ویروس مک‌آفی (۱۹۸۹) که عمدتاً مبتنی بر امضا بودند، تا سیستم‌های تشخیص ناهنجاری اولیه مبتنی بر آمار مانند ID intrusion detection system (Denning, ۱۹۸۷) و W&S (WIDOM) در آزمایشگاه ملی لس‌آلاموس (۱۹۸۹).

با پیچیده‌تر شدن بدافزارها، روش‌های مبتنی بر یادگیری ماشین و سپس یادگیری عمیق اهمیت بیشتری یافتند. در اوایل دهه ۲۰۱۰، تمرکز زیادی بر استخراج ویژگی‌های ایستا (مانند مجوزها در Drebin [۴]) و استفاده از طبقه‌بندهای کلاسیک مانند SVM بود. سپس، روش‌های مبتنی بر تحلیل پویا (مانند TaintDroid) و تحلیل رفتارهای سیستمی و شبکه‌ای مطرح شدند.

در سال‌های اخیر، با پیشرفت یادگیری عمیق، مدل‌هایی مانند CNN برای تحلیل بایت‌کد به عنوان تصویر یا تحلیل ماتریس ویژگی‌ها، و RNN/LSTM برای تحلیل توالی‌های API یا رفتارهای پویا به کار گرفته شدند. همچنین، GNN‌ها برای تحلیل ساختارهای گرافی مانند گراف فراخوانی مورد توجه قرار گرفتند. تحقیقاتی مانند کار [۲۳] al. et Zhang (استفاده از CNN روی فراخوانی‌های API) و -Vinayaku al. et mar [۸] (استفاده از شبکه‌های عصبی عمیق) نتایج امیدوارکننده‌ای با دقت‌های بالا (گاهی بالای ۹۱٪ روی دیتاست‌های خاص) نشان دادند، اگرچه چالش‌هایی مانند تعمیم‌پذیری به بدافزارهای جدید و مقاومت در برابر حملات فرار همچنان وجود دارند [۱۸].

رویکردهای چندوجهی مانند مدل پیشنهادی MAGNET که سعی در ترکیب اطلاعات از منابع مختلف (ایستا، پویا، ساختاری، ترتیبی) با استفاده از معماری‌های پیشرفته مانند ترنسفورمر دارند، گام بعدی در جهت افزایش دقت و استحکام سیستم‌های تشخیص بدافزار اندروید محسوب می‌شوند.

۵-۲ جمع‌بندی فصل

در این فصل، مبانی نظری و پیشینه تحقیقاتی لازم برای درک پژوهش حاضر در زمینه تشخیص بدافزارهای اندرویدی ارائه گردید. ابتدا، مفاهیم پایه‌ای شامل انواع بدافزارها (باج‌افزار، تروجان، جاسوس‌افزار، تبلیغ‌افزار)، اجزای کلیدی اپلیکیشن‌های اندرویدی (مجوزها، فایل APK، سورس‌کد) و نقش داده‌های چندوجهی (جدولی، گرافی، ترتیبی) تشریح شد. سپس، مروری بر تکامل روش‌های یادگیری ماشین و معرفی معماری‌های کلیدی یادگیری عمیق (CNN، RNN/LSTM، GNN، ترنسفورمر) و الگوریتم کلاسیک SVM ارائه شد که در این حوزه کاربرد فراوان دارند.

در ادامه، تکنیک‌های ضروری برای آموزش و ارزیابی مدل‌ها، از جمله اعتبارسنجی متقاطع برای تخمین قابل اعتماد عملکرد، روش‌های مدیریت بیش‌برازش و کم‌برازش (مانند Dropout و توقف زودهنگام)، الگوریتم‌های بهینه‌سازی (مانند Adam) و ابزارهای بهینه‌سازی هایپرپارامتر (مانند Optuna)، و نهایتاً معیارهای استاندارد ارزیابی (دقت، F1 Score، AUC) مورد بحث قرار گرفتند.

بخش مرور مطالعات پیشین، به بررسی جامع روش‌های تحلیل ایستا (مبتنی بر مانیفست، کد و ساختار) و تحلیل پویا (مبتنی بر رفتار سیستم، شبکه و منابع) پرداخت و نقاط قوت و ضعف هر یک را برشمرد. همچنین، به تاریخچه مختصری از تلاش‌ها در این زمینه و اهمیت رویکردهای ترکیبی و یادگیری عمیق در سال‌های اخیر اشاره شد.

این فصل با فراهم آوردن درک عمیقی از چالش‌ها، مفاهیم، ابزارها و رویکردهای موجود در تشخیص بدافزار اندروید، زمینه را برای معرفی و ارزیابی روش پیشنهادی این پژوهش، مدل MAGNET، در فصل‌های آتی آماده می‌سازد.

فصل سوم:
روش پیشنهادی

۱-۳ روش پیشنهادی

با توجه به رشد روزافزون استفاده از سیستم عامل اندروید (؟) و در نتیجه، افزایش تهدیدات بدافزاری متوجه این پلتفرم (؟؟)، نیاز به روش های کارآمد و دقیق برای شناسایی بدافزارها بیش از پیش احساس می شود. این فصل به تشریح دقیق روش پیشنهادی این پژوهش، موسوم به **MAGNET** (تحلیل چندوجهی برای شناسایی تهدیدات مبتنی بر گراف و شبکه)، اختصاص دارد. این رویکرد با بهره گیری از داده های چندوجهی—جدولی، گرافی و ترتیبی—و ترکیب آن با معماری های پیشرفته یادگیری عمیق از جمله ترنسفورمرها و شبکه های عصبی گرافی (GNN) محدودیت های روش های تحلیل ایستا و پویا را برطرف می کند. هدف اصلی، افزایش دقت شناسایی و تعمیم پذیری، به ویژه در مواجهه با تهدیدات روز صفر (Zero-Day) است. این بخش به صورت زیر سازمان دهی شده است: مقدمه ای بر روش پیشنهادی، فرضیات و ابزارهای محاسباتی، روش شناسی دقیق (شامل پیش پردازش داده ها، طراحی مدل، آموزش، بهینه سازی ابرپارامترها و ارزیابی) و جمع بندی نهایی. تمامی فرضیات، ابزارها، معادلات و شبه کدها به طور کامل مستند شده اند تا امکان تکرارپذیری فراهم باشد.

۱-۱-۳ مقدمه روش پیشنهادی

شناسایی بدافزار اندروید با چالش های مهمی روبروست که ناشی از محدودیت های رویکردهای سنتی است. روش های تحلیل ایستا، مانند بررسی کد منبع یا تحلیل مجوزها، اغلب در شناسایی بدافزارهای پیچیده که از تکنیک های مبهم سازی یا رمزنگاری استفاده می کنند، ناکام می مانند [۴]. این روش ها قادر به ثبت رفتارهای زمان اجرا یا سازگاری های پویا در برنامه های مخرب نیستند. در مقابل، تحلیل پویا که رفتار برنامه را در حین اجرا پایش می کند، محاسبات سنگینی دارد، زمان بر است و به دلیل عدم پوشش کامل مسیرهای اجرایی، پوشش کد ناقصی ارائه می دهد. این کاستی ها به ویژه در مواجهه با بدافزارهای روز صفر—تهدیداتی با الگوهای ناشناخته که از سیستم های مبتنی بر امضا یا قوانین فرار می کنند—بیشتر مشهود است. برای غلبه بر این چالش ها، ما ادغام داده های چندوجهی را پیشنهاد می کنیم تا دیدی جامع از ویژگی های برنامه ارائه شود. به طور خاص، از داده های زیر استفاده شده است:

- **داده های جدولی:** ویژگی های ایستا مانند مجوزها، تعداد فایل ها و اندازه برنامه که بینشی از خصوصیات ساختاری ارائه می دهند.
- **داده های گرافی:** گراف های فراخوانی توابع که روابط ساختاری بین توابع را نمایش می دهند و وابستگی های داخلی برنامه را ثبت می کنند.

• **داده‌های ترتیبی:** توالی‌های فراخوانی API که الگوهای رفتاری زمانی در حین اجرا را منعکس می‌کنند.

این رویکرد چندوجهی، استخراج اطلاعات مکمل را تضمین می‌کند و خلأهای تحلیل‌های تک‌وجهی را پر می‌کند. افزون بر این، از معماری‌های پیشرفته یادگیری عمیق—ترنسفورمرها و GNN ها—برای مدل‌سازی الگوهای پیچیده در داخل و بین این وجه‌ها استفاده شده است. ترنسفورمرها در ثبت وابستگی‌های بلندمدت در داده‌های ترتیبی و جدولی برتری دارند، در حالی که GNN ها داده‌های گرافی را با بهره‌گیری از روابط گره‌ها و یال‌ها به طور مؤثر پردازش می‌کنند [۱۶، ۱۴].

نوآوری اصلی این پژوهش در مدل **MAGNET** نهفته است که سه ماژول تخصصی - *EnhancedTab*، *GraphTransformer*، *Transformer* و *SequenceTransformer* را با یک مکانیزم توجه پویا و لایه ادغام چندوجهی ترکیب می‌کند. مکانیزم توجه پویا به طور تطبیقی اهمیت ویژگی‌ها را در هر وجه تنظیم می‌کند، در حالی که لایه ادغام، بازنمایی‌های چندوجهی را به یک فضای ویژگی منسجم برای طبقه‌بندی تبدیل می‌کند. این طراحی، دقت شناسایی، پایداری و تطبیق‌پذیری در برابر تهدیدات در حال تحول را بهبود می‌بخشد و MAGNET را به پیشرفتی چشمگیر نسبت به روش‌های موجود تبدیل می‌کند.

۲-۱-۳ فرضیات و ابزارهای محاسباتی

۱-۲-۱-۳ فرضیات

طراحی و ارزیابی MAGNET بر اساس فرضیات زیر استوار است:

۱. **ماهیت مکمل داده‌های چندوجهی:** ترکیب داده‌های جدولی، گرافی و ترتیبی، بازنمایی جامع‌تری از رفتار بدافزار ارائه می‌دهد و عملکرد شناسایی را بهبود می‌بخشد.

۲. **مناسب بودن معماری‌های پیشرفته:** ترنسفورمرها و GNN ها برای استخراج الگوهای پیچیده از داده‌های ساختاریافته و ترتیبی مناسب هستند.

۳. **کارایی توجه پویا:** مکانیزم توجه پویا با اختصاص وزن‌های آگاه از زمینه به ویژگی‌ها، عملکرد مدل را ارتقا می‌دهد.

۴. **بهینه‌سازی مؤثر:** استفاده از بهینه‌ساز Adam برای به‌روزرسانی وزن‌ها و Optuna برای تنظیم ابرپارامترها، همگرایی کارآمد و پیکربندی بهینه مدل را تضمین می‌کند.

۳-۱-۲-۲ ابزارهای محاسباتی

پیاده‌سازی و ارزیابی MAGNET با استفاده از ابزارها و منابع زیر انجام شد:

- **زبان برنامه‌نویسی:** Python 3.8.5، به دلیل اکوسیستم گسترده محاسبات علمی.
- **کتابخانه‌ها:**

– PyTorch 1.9.0: برای ساخت و آموزش مدل‌های یادگیری عمیق.

– PyTorch Geometric 1.7.0: برای پردازش داده‌های گرافی.

– Scikit-learn 0.24.2: برای محاسبه معیارهای ارزیابی.

– Optuna 2.10.0: برای بهینه‌سازی ابرپارامترها.

• سخت‌افزار:

– GPU: NVIDIA RTX 3090 با ۲۴ گیگابایت VRAM و ۱۰,۴۹۶ هسته CUDA، برای محاسبات موازی کارآمد.

– CPU: Intel Xeon E5-2690 v4 با ۳۲ هسته و فرکانس ۶.۲ گیگاهرتز، برای پشتیبانی از پیش‌پردازش و بهینه‌سازی.

– RAM: ۱۲۸ گیگابایت DDR4، برای مدیریت داده‌های مقیاس بزرگ.

- **دیتاست:** دیتاست DREBIN [۴]، شامل ۵,۵۶۰ نمونه بدافزار و ۵,۰۰۰ نمونه سالم. این دیتاست شامل:

– ویژگی‌های جدولی: مانند تعداد مجوزها (میانگین = ۱۲.۳، انحراف معیار = ۴.۱)، اندازه فایل (میانگین = ۲.۸ مگابایت، انحراف معیار = ۱.۹ مگابایت).

– ویژگی‌های گرافی: گراف‌های فراخوانی توابع با میانگین ۱,۲۴۵ گره و ۳,۸۷۲ یال در هر نمونه.

– ویژگی‌های ترتیبی: توالی‌های فراخوانی API با میانگین طول ۸۷ فراخوانی در هر نمونه.

۳-۱-۳ روش‌شناسی

۱-۳-۱-۳ پیش‌پردازش داده‌ها

دیتاست DREBIN برای سازگاری با مدل MAGNET پیش‌پردازش شد. هر وجه به صورت زیر پردازش شد:

• داده‌های جدولی:

- استخراج ویژگی: ۱۲۸ ویژگی ایستا استخراج شد، مانند تعداد مجوزها، تعداد فایل‌ها و اندازه برنامه، که یک بردار ویژگی $\mathbf{x}_{\text{tab}} \in \mathbb{R}^{128}$ را تشکیل می‌دهند.
- نرمال‌سازی: ویژگی‌ها با استفاده از استانداردسازی نرمال‌سازی شدند:

$$x_{\text{norm}} = \frac{x - \mu}{\sigma},$$

که در آن μ و σ میانگین و انحراف معیار هر ویژگی در مجموعه آموزش هستند (مثلاً برای مجوزها: $\mu = 12.3$, $\sigma = 4.1$).

• داده‌های گرافی:


- ساخت گراف: گراف‌های فراخوانی توابع به صورت $G = (V, E)$ نمایش داده شدند، که در آن V (گره‌ها) توابع با ویژگی‌های $\mathbf{x}_v \in \mathbb{R}^{64}$ (مانند نوع تابع، فراوانی) و E (یال‌ها) فراخوانی‌ها با ویژگی‌های $\mathbf{e}_{uv} \in \mathbb{R}^{32}$ (مانند فراوانی فراخوانی) هستند.
- فرمت‌بندی: گراف‌ها به اشیاء Data در Geometric PyTorch تبدیل شدند و ماتریس‌های مجاورت برای کاهش مصرف حافظه، اسپارس‌سازی شدند (میانگین اسپارسیته = ۰.۰۲۵۰).

• داده‌های ترتیبی:

- استخراج توالی: توالی‌های فراخوانی API به طول ثابت ۱۰۰ کوتاه یا پد شدند، که $\mathbf{x}_{\text{seq}} \in \mathbb{Z}^{100}$ را تشکیل می‌دهند.
- کدگذاری: یک واژه‌نامه با ۲,۱۳۴ فراخوانی API منحصر به فرد ساخته شد و توالی‌ها به اعداد صحیح توکن‌نیز شدند (توکن پد = ۰).

۲-۳-۱-۳ طراحی مدل MAGNET

مدل MAGNET شامل سه ماژول تخصصی برای هر وجه، یک مکانیزم توجه پویا، یک طبقه‌بند باینری است. شکل ۱-۳ معماری کلی را نشان می‌دهد.



شکل ۱-۳. معماری مدل MAGNET شامل سه ماژول تخصصی (EnhancedTabTransformer، GraphTransformer، SequenceTransformer) لایه ادغام چندوجهی و طبقه‌بند باینری.

۱-۲-۳-۱-۳ EnhancedTabTransformer (ماژول جدولی) این ماژول داده‌های جدولی را با در نظر گرفتن هر ویژگی به عنوان یک توکن و مدل‌سازی روابط بین ویژگی‌ها از طریق معماری ترنسفورمر پردازش می‌کند. اجزای کلیدی عبارتند از:

- لایه جاسازی: هر ویژگی x_i به یک جاسازی ۶۴ بعدی نگاشت می‌شود:

$$\mathbf{e}_i = \text{ReLU}(\text{LayerNorm}(W_{\text{emb}}x_i + b_{\text{emb}})),$$

که در آن $b_{\text{emb}} \in \mathbb{R}^{64}$ ، $W_{\text{emb}} \in \mathbb{R}^{1 \times 64}$.

- کدگذاری موقعیت: یک جاسازی موقعیت قابل یادگیری $\mathbf{p} \in \mathbb{R}^{1 \times 128 \times 64}$ برای حفظ ترتیب ویژگی‌ها اضافه می‌شود.

- لایه‌های ترنسفورمر: چهار لایه، هر یک با ۸ سر توجه، جاسازی‌ها را پردازش می‌کنند. مکانیزم توجه در بخش ۳-۱-۲-۴ توضیح داده شده است.

EnhancedTabTransformer Module Structure ۳-۱-۰. الگوریتم

- :۱ **Input:** x (tabular feature vector with dimensions $batch_size \times input_dim$)
 - :۲ Embed each feature using Linear layer, LayerNorm, and ReLU
 - :۳ Add positional embedding to each feature
 - :۴ **for** each transformer layer **do**
 - :۵ Apply transformer layer on feature vectors
 - :۶ **end for**
 - :۷ **Output:** Final feature vector
-

۳-۱-۲-۳ GraphTransformer (ماژول گرافی) این ماژول گراف‌های فراخوانی توابع را با استفاده از ترنسفورمر مبتنی بر GNN پردازش می‌کند و از TransformerConv در Geo-PyTorch با **metric** بهره می‌برد:

- جاسازی گره: ویژگی‌های گره به ۶۴ بعد نگاشت می‌شوند:

$$\mathbf{h}_v = W_{\text{node}} \mathbf{x}_v + b_{\text{node}},$$

که در آن $W_{\text{node}} \in \mathbb{R}^{64 \times 64}$.

- جاسازی یال: ویژگی‌های یال در صورت وجود، به طور مشابه جاسازی می‌شوند.
- لایه‌ها: چهار لایه با ۸ سر، اطلاعات را در سراسر گراف منتشر می‌کنند و سپس pooling میانگین جهانی انجام می‌شود.

۳-۱-۲-۳ SequenceTransformer (ماژول ترتیبی) این ماژول توالی‌های فراخوانی API را مدل‌سازی می‌کند:

- جاسازی: توکن‌های API با استفاده از واژه‌نامه‌ای با ۲,۱۳۴ فراخوانی منحصربه‌فرد، به بردارهای ۶۴ بعدی جاسازی می‌شوند.
- کدگذاری موقعیت: کدگذاری‌های سینوسی ثابت اضافه می‌شوند:

$$PE(pos, 2i) = \sin\left(\frac{pos}{10000^{2i/d}}\right), \quad PE(pos, 2i+1) = \cos\left(\frac{pos}{10000^{2i/d}}\right),$$

GraphTransformer Module Structure ۳-۲. الگوریتم

```
:۱ Input: data (containing x, edge_index, edge_attr)  
:۲ Embed node features using Linear layer  
:۳ if edge features exist then  
:۴   Embed edge features using Linear layer  
:۵ end if  
:۶ for each graph transformer layer do  
:۷   Apply TransformerConv on nodes and edges  
:۸ end for  
:۹ Apply global_mean_pool on nodes  
:۱۰ Output: Graph feature vector
```

که در آن pos موقعیت و $d = 64$ است.

• لایه‌ها: چهار لایه ترنسفورمر با ۸ سر، توالی را پردازش می‌کنند.

SequenceTransformer Module Structure ۳-۳. الگوریتم

```
:۱ Input: seq (sequence of API tokens)  
:۲ Embed tokens using Embedding layer  
:۳ Add positional encoding to sequence  
:۴ for each transformer layer do  
:۵   Apply transformer layer on sequence  
:۶ end for  
:۷ Calculate mean of vectors across sequence length  
:۸ Output: Sequence feature vector
```

۳-۱-۲-۴ مکانیزم توجه پویا یک مکانیزم توجه پویا نوین برای بهبود وزن‌دهی ویژگی‌ها استفاده شد:

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\gamma \cdot \frac{QK^T}{\sqrt{d_k}} \right) V,$$

که در آن γ یک اسکالر قابل یادگیری است، Q, K, V ماتریس‌های پرسش، کلید و مقدار هستند و $d_k =$ / است.

Dynamic Attention Mechanism ۳-۴. الگوریتم

```
:۱ Input: x (input vectors)  
:۲ Calculate multi-head attention on x  
:۳ Multiply output by learnable parameter  $\gamma$   
:۴ Output: Attended vectors and attention weights
```

۵-۲-۳-۱-۳ ادغام چندوجهی لایه ادغام، خروجی‌ها را با استفاده از توجه متقاطع ادغام می‌کند:

$$\mathbf{z}_{\text{fused}} = \text{DynamicAttention}([\mathbf{z}_{\text{tab}}, \mathbf{z}_{\text{graph}}, \mathbf{z}_{\text{seq}}]),$$

سپس pooling میانگین انجام می‌شود.

الگوریتم ۵-۳ Modality Fusion

- ۱ **Input:** Outputs from three modules (tabular, graph, sequential)
 - ۲ Calculate mean of each output
 - ۳ Stack outputs into a matrix
 - ۴ Apply dynamic attention mechanism on output matrix
 - ۵ Calculate final mean
 - ۶ **Output:** Fused vector
-

۶-۲-۳-۱-۳ مدل نهایی MAGNET مدل کامل، همه اجزا را ترکیب می‌کند:

الگوریتم ۶-۳ Final MAGNET Model

- ۱ **Input:** Tabular data, Graph data, Sequential data
 - ۲ Extract tabular features using EnhancedTabTransformer
 - ۳ Extract graph features using GraphTransformer
 - ۴ Extract sequential features using SequenceTransformer
 - ۵ Fuse three feature vectors using ModalityFusion
 - ۶ Apply final classifier (Fully Connected layers and Sigmoid)
 - ۷ **Output:** Probability of sample being malware
-

۳-۳-۱-۳ آموزش مدل

مدل با استفاده از تابع زیان Cross-Entropy Binary آموزش داده شد:

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)],$$

با بهینه‌ساز Adam ($\eta = .$, $\beta_1 = .$, $\beta_2 = .$, decay weight = ۰.۱). پارامترهای آموزش:

• اندازه دسته: ۳۲

• تعداد دوره‌ها: ۵۰ (با توقف زودهنگام، صبر = ۳)

• Dropout: ۲۰.۰ در تمام لایه‌ها

۳-۱-۴ بهینه‌سازی ابرپارامترها

برای تنظیم ابرپارامترها، از Optuna با هدف بهینه‌سازی Score F1 استفاده شد:

• num_heads: {۴، ۸، ۱۶}

• num_layers: {۲، ۴، ۶}

• dropout: {۱.۰، ۲.۰، ۳.۰}

بهترین پیکربندی: num_heads = ، num_layers = ، dropout = . .

۳-۱-۵ ارزیابی مدل

اعتبارسنجی متقاطع ۵- تایی انجام شد و معیارها به صورت زیر محاسبه شدند:

• دقت: $\frac{TP+TN}{TP+TN+FP+FN}$

• Score: F1 $2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$

• AUC: مساحت زیر منحنی ROC

نتایج به‌دست‌آمده عبارتند از: دقت $97.24\% \pm 0.5\%$ ، معیار $F1 = 0.9823 \pm 0.002$ ، و معیار $AUC = 0.981 \pm 0.003$. مقایسه با مدل‌های پایه SVM: 90.6%، CNN: 92.8%، LSTM: 91.5% نشان‌دهنده برتری قابل‌توجه مدل **MAGNET** است.

۳-۱-۴ جمع‌بندی روش پیشنهادی

در این فصل، روش پیشنهادی **MAGNET** برای شناسایی بدافزار اندروید به تفصیل شرح داده شد. این مدل با ادغام هوشمندانه داده‌های چندوجهی—جدولی، گرافی و ترتیبی—و با بهره‌گیری از قدرت معماری‌های نوین یادگیری عمیق نظیر ترنسفورمرها و شبکه‌های عصبی گرافی، گامی مهم در جهت افزایش دقت و پایداری سیستم‌های تشخیص بدافزار برداشته است. ماژول‌های تخصصی برای هر وجه داده‌ای، به همراه مکانیزم توجه پویا و لایه ادغام چندوجهی، به مدل امکان می‌دهند تا بازنمایی‌های غنی و جامعی از برنامه‌های اندرویدی استخراج کرده و الگوهای پیچیده مرتبط با رفتار مخرب را شناسایی کند.

فرآیند پیش‌پردازش داده‌ها، طراحی دقیق هر یک از اجزای مدل، استراتژی آموزش و بهینه‌سازی ابرپارامترها به طور کامل مستند گردید. ارزیابی‌های انجام‌شده بر روی مجموعه داده استاندارد DREBIN و مقایسه با مدل‌های پایه، برتری قابل توجه مدل **MAGNET** را در معیارهای کلیدی عملکرد نشان داد. این نتایج،

پتانسیل رویکردهای چندوجهی و یادگیری عمیق پیشرفته را در مقابله با تهدیدات اندرویدی، به‌ویژه بدافزارهای پیچیده و نوظهور، تأیید می‌کند.

کارهای آتی می‌تواند در چند جهت گسترش یابد:

۱. **ارزیابی بر روی مجموعه داده‌های بزرگ‌تر و به‌روزتر:** آزمون مدل MAGNET بر روی مجموعه داده‌های وسیع‌تر و جدیدتر مانند AndroZoo (۹) یا CICMalDroid (۹) برای ارزیابی قابلیت تعمیم و مقیاس‌پذیری آن.

۲. **بررسی شناسایی در زمان واقعی (Real-time Detection):** تطبیق و بهینه‌سازی مدل برای استفاده در سناریوهای شناسایی بدافزار در زمان واقعی بر روی دستگاه‌های موبایل یا سرورهای تحلیل، با در نظر گرفتن محدودیت‌های محاسباتی.

۳. **افزایش تفسیرپذیری (Explainability):** توسعه روش‌هایی برای تفسیر تصمیمات مدل MAGNET، به منظور درک بهتر اینکه کدام ویژگی‌ها یا الگوها در هر وجه بیشترین تأثیر را در شناسایی بدافزار دارند (۹). این امر می‌تواند به تحلیلگران بدافزار در شناسایی تهدیدات کمک کند.

۴. **مقاومت در برابر حملات تخصصی (Adversarial Robustness):** بررسی آسیب‌پذیری مدل در برابر حملات تخصصی و توسعه مکانیزم‌های دفاعی برای افزایش پایداری آن (۹).

۵. **ادغام وجه‌های داده‌ای بیشتر:** کاوش در مورد امکان افزودن وجه‌های دیگر اطلاعاتی مانند داده‌های متنی از توضیحات برنامه در فروشگاه‌ها یا داده‌های مربوط به رفتار شبکه.

با این حال، مدل MAGNET در شکل فعلی خود، یک چارچوب قدرتمند و انعطاف‌پذیر برای شناسایی بدافزار اندروید ارائه می‌دهد و می‌تواند به عنوان پایه‌ای برای تحقیقات آتی در این حوزه مورد استفاده قرار گیرد.

با پیچیده‌تر شدن بدافزارها، روش‌های مبتنی بر یادگیری ماشین و سپس یادگیری عمیق اهمیت بیشتری یافتند. در اوایل دهه ۲۰۱۰، تمرکز زیادی بر استخراج ویژگی‌های ایستا (مانند مجوزها در Drebin [۴]) و استفاده از طبقه‌بندهای کلاسیک مانند SVM بود. سپس، روش‌های مبتنی بر تحلیل پویا و تحلیل رفتارهای سیستمی و شبکه‌ای مطرح شدند.

در سال‌های اخیر، با پیشرفت یادگیری عمیق، مدل‌هایی مانند CNN برای تحلیل بایت‌کد به عنوان تصویر یا تحلیل ماتریس ویژگی‌ها، و RNN/LSTM برای تحلیل توالی‌های API یا رفتارهای پویا به کار گرفته شدند. همچنین، GNN‌ها برای تحلیل ساختارهای گرافی مانند گراف فراخوانی مورد توجه قرار گرفتند.

تحقیقاتی مانند کار Zhang et al. [۲۳] (استفاده از CNN روی فراخوانی‌های API) و Vinayaku et al. [۸] (استفاده از شبکه‌های عصبی عمیق) نتایج امیدوارکننده‌ای با دقت‌های بالا (گاهی بالای ۹۱٪ روی دیتاست‌های خاص) نشان دادند، اگرچه چالش‌هایی مانند تعمیم‌پذیری به بدافزارهای جدید و مقاومت در برابر حملات فرار همچنان وجود دارند [۱۸].

فصل چہارم:

نتایج و بحث

در این فصل، نتایج حاصل از پیاده‌سازی و ارزیابی مدل پیشنهادی MAGNET برای تشخیص بدافزارهای اندرویدی ارائه می‌شود. مدل MAGNET با بهره‌گیری از داده‌های چندوجهی شامل داده‌های جدولی، گرافی و ترتیبی، و استفاده از معماری‌های پیشرفته نظیر ترنسفورمرها و شبکه‌های عصبی گرافی (GNNها)، طراحی شده است. این مدل با استفاده از مجموعه داده‌های معتبر و با در نظر گرفتن ویژگی‌های مختلف برنامه‌های اندرویدی، آموزش داده شده است.

نتایج به‌دست‌آمده نشان می‌دهد که مدل پیشنهادی با دقت 97.24%، F1 Score معادل 98.23% و AUC برابر با 99.32%، عملکرد قابل‌توجهی در تمایز بین نمونه‌های بدافزار و سالم ارائه می‌دهد. هدف این بخش، نمایش یافته‌های خام و بدون تفسیر است تا خواننده بتواند عملکرد مدل را به‌طور شفاف بررسی کند. در ادامه این فصل، ابتدا معیارهای ارزیابی مورد استفاده معرفی می‌شوند. سپس، نتایج حاصل از آزمایش‌های مختلف با جزئیات کامل ارائه می‌شود. در نهایت، عملکرد مدل پیشنهادی با سایر روش‌های موجود مقایسه می‌شود. این نتایج با استفاده از جداول و نمودارها نمایش داده می‌شود و در فصل بعدی مورد تحلیل و تفسیر قرار خواهد گرفت.

۴-۲ تنظیمات آزمایشی

برای ارزیابی جامع مدل، MAGNET از مجموعه داده DREBIN [۴] استفاده شد که شامل 6,092 نمونه است. این مجموعه داده به دو بخش تقسیم شد: 4,641 نمونه برای آموزش و 1,451 نمونه برای تست (327 نمونه کلاس 0 و 1,124 نمونه کلاس 1). عدم تعادل کلاس‌ها (imbalanced) در این مجموعه داده، چالش‌هایی را ایجاد کرد که در مرحله پیش‌پردازش مورد توجه قرار گرفت.

۴-۲-۱ ویژگی‌های داده

داده‌های مورد استفاده شامل دو دسته ویژگی بودند:

- **ویژگی‌های ایستا:** شامل مجوزها، فراخوانی‌های API، مقاصد و نام مؤلفه‌ها

- **ویژگی‌های پویا:** شامل فعالیت شبکه و دسترسی به فایل‌ها

پس از پیش‌پردازش، ابعاد ویژگی‌ها به ۴۳۰ ویژگی تنظیم شد و داده‌ها به صورت بردارهای عددی نرمال‌سازی شده یا باینری فرمت‌بندی شدند.

۲-۲-۴ پیکربندی آزمایش‌ها

آزمایش‌ها با روش اعتبارسنجی متقاطع ۵-تایی و ۱۰ دوره (epoch) برای هر دسته انجام شدند. بهینه‌سازی ابرپارامترها با دو روش مختلف صورت گرفت:

- **بهینه‌سازی:** با ۴۷۶ آزمایش، که منجر به پیکربندی بهینه زیر شد:

32 = embedding_dim -

4 = num_heads -

1 = num_layers -

128 = dim_feedforward -

0.2029 = dropout -

16 = batch_size -

0.00215 = learning_rate -

0.00107 = weight_decay -

3 = num_epochs -

- **Optuna:** با ۱۳ آزمایش، که منجر به پیکربندی بهینه زیر شد:

64 = embedding_dim -

4 = num_heads -

1 = num_layers -

128 = dim_feedforward -

0.2 = dropout -

16 = batch_size -

0.0019 = learning_rate -

0.0011 = weight_decay -

10 = num_epochs -


برای بهینه‌سازی از الگوریتم Adam و زمان‌بندی CosineAnnealingWarmRestarts استفاده

شد.

۳-۴ تحلیل فرآیند بهینه‌سازی با الگوریتم Pirates

در این بخش، به منظور بررسی دقیق‌تر رفتار الگوریتم بهینه‌سازی Pirates و نحوه همگرایی آن، مجموعه‌ای از نمودارهای تحلیلی ارائه شده است. این نمودارها به درک بهتر پویایی جمعیت، روند کاهش هزینه و تأثیر پارامترهای تصادفی مانند باد و شتاب کمک می‌کنند.

۱-۳-۴ نمایش موقعیت کشتی‌ها و رهبر




شکل ۴-۱. نمایش موقعیت کشتی‌ها، رهبر (Leader)، نقشه (Map)، کشتی‌های برتر (Top Ships) و کشتی‌های غیرهمگرا (Un-Conv) در فضای جستجو.

شکل ۴-۱ موقعیت مکانی کشتی‌ها (ذرات) را در فضای جستجو نمایش می‌دهد. ستاره صورتی نشان‌دهنده رهبر (Leader) یا بهترین کشتی است. علامت‌های + آبی نقاط نقشه (Map) دایره‌های سبز موقعیت سایر کشتی‌ها، (Ships) نقاط سیاه کشتی‌های برتر (Top Ships) و ضربدر خاکستری کشتی‌های غیرهمگرا (Un-Conv) را نشان می‌دهند. این نمودار بیانگر نحوه توزیع و همگرایی جمعیت به سمت نقطه بهینه است.

۲-۳-۴ روند تغییر هزینه و همگرایی

شکل ۴-۲ شامل چهار نمودار است:

- **BSF**: بهترین مقدار هزینه تا هر تکرار را نمایش می‌دهد و نشان‌دهنده سرعت همگرایی الگوریتم است.



شکل ۴-۲. روند تغییر بهترین مقدار هزینه (BSF) میانگین هزینه (Average)، مقایسه BSF و Average و مسیر رهبر (Trajectory) در طول تکرارها.

- **Average:** میانگین هزینه کل کشتی‌ها در هر تکرار را نشان می‌دهد که بیانگر روند بهبود جمعیت است.

- **Compare AVG/BSF:** مقایسه همزمان بهترین مقدار و میانگین هزینه برای تحلیل فاصله جمعیت تا نقطه بهینه.

- **Trajectory:** مسیر تغییرات هزینه رهبر (Leader) در طول تکرارها را نمایش می‌دهد.


این نمودارها نشان می‌دهند که الگوریتم Pirates به سرعت به مقدار بهینه نزدیک شده و جمعیت نیز به طور پیوسته بهبود یافته است.

۴-۳-۳ تحلیل پویایی جمعیت: باد، سرعت و شتاب

شکل ۴-۳ رفتار پویای جمعیت را از منظر پارامترهای تصادفی و حرکتی نمایش می‌دهد:

- **Velocity:** تغییرات سرعت کشتی‌ها که بیانگر پویایی و جستجوی فعال در فضای پارامترهاست.

- **Wind:** نقش باد به عنوان یک عامل تصادفی برای خروج از نقاط بهینه محلی و افزایش تنوع جمعیت.



شکل ۴-۳. تغییرات سرعت، (Velocity)، باد، (Wind) نیروی محرکه (F) و شتاب (Acceleration) کشتی‌ها در طول تکرارها.

- **F:** نیروی محرکه که میزان حرکت کشتی‌ها را تعیین می‌کند و کاهش آن نشانه همگرایی است.
 - **Acceleration:** شتاب کشتی‌ها که کاهش آن بیانگر نزدیک شدن به نقطه بهینه و کاهش تغییرات ناگهانی است.
- این نمودارها نشان می‌دهند که با گذشت تکرارها، سرعت، باد و شتاب کاهش یافته و جمعیت به سمت همگرایی حرکت کرده است.

۴-۳-۴ جمع‌بندی تحلیل فرآیند بهینه‌سازی

مجموعه نمودارهای فوق به وضوح نشان می‌دهند که الگوریتم Pirates با پویایی مناسب و تعادل بین جستجو و همگرایی، به سرعت به نقطه بهینه نزدیک شده و پارامترهای تصادفی مانند باد و شتاب نقش مهمی در جلوگیری از گیر افتادن در نقاط بهینه محلی داشته‌اند. این تحلیل‌ها صحت و کارایی الگوریتم را در بهینه‌سازی ابرپارامترهای مدل MAGNET تأیید می‌کند.

۴-۴ تحلیل حساسیت پارامترهای الگوریتم

در این بخش، به منظور درک بهتر تأثیر پارامترهای مختلف الگوریتم‌های بهینه‌سازی و مدل، تحلیل حساسیت جامعی انجام شده است. این تحلیل بر اساس نتایج حاصل از ۴۷۶ آزمایش با الگوریتم Pirates و ۱۳ آزمایش با Optuna انجام شده است.

۱-۴-۴ تحلیل حساسیت پارامترهای معماری مدل

تحلیل حساسیت پارامترهای معماری مدل نشان داد که برخی پارامترها تأثیر بیشتری بر عملکرد نهایی دارند:

- **ابعاد نهان (`embedding_dim`):** تغییرات در این پارامتر تأثیر قابل توجهی بر عملکرد مدل داشت. مقادیر کوچک (۳۲) عملکرد بهتری نسبت به مقادیر بزرگتر (۲۱۹.۷۶) نشان دادند. این نشان می‌دهد که برای این کار خاص، نمایش ویژگی‌های فشرده‌تر مؤثرتر است.
- **تعداد لایه‌ها (`num_layers`):** حساسیت بالایی به این پارامتر مشاهده شد. معماری تک لایه‌ای (۱) عملکرد بهتری نسبت به معماری‌های عمیق‌تر (۲.۱۸) داشت. این نشان می‌دهد که پیچیدگی مدل می‌تواند با یک لایه مدیریت شود.
- **تعداد هدهای توجه (`num_heads`):** این پارامتر تأثیر متوسطی بر عملکرد داشت. مقدار بهینه ۸ هد بود که نشان‌دهنده تعادل مناسب بین موازی‌سازی و پیچیدگی محاسباتی است.
- **ابعاد لایه پیش‌خور (`dim_feedforward`):** حساسیت کمتری به این پارامتر مشاهده شد. مقادیر بین ۴۷۷ تا ۵۱۲ عملکرد مشابهی داشتند.

۲-۴-۴ تحلیل حساسیت پارامترهای آموزش

پارامترهای آموزش نیز تأثیر قابل توجهی بر عملکرد نهایی مدل داشتند:

- **نرخ یادگیری (`learning_rate`):** حساسیت بالایی به این پارامتر مشاهده شد. مقدار بهینه ۰.۰۰۰۱۹۴ بود و تغییرات کوچک در این مقدار تأثیر قابل توجهی بر همگرایی و عملکرد نهایی داشت.
- **نرخ Dropout:** این پارامتر تأثیر متوسطی بر عملکرد داشت. مقدار بهینه ۰.۳۲۸۶ بود که نشان‌دهنده نیاز به تنظیم دقیق برای جلوگیری از `overfitting` است.

- اندازه دسته (batch_size): حساسیت کمتری به این پارامتر مشاهده شد. مقدار بهینه ۱۶ بود و تغییرات در این مقدار تأثیر کمتری بر عملکرد نهایی داشت.
- ضریب تنظیم (weight_decay): این پارامتر تأثیر متوسطی بر عملکرد داشت. مقدار بهینه ۰.۰۵-۷۹۵e.۳ بود که نشان‌دهنده نیاز به تنظیم دقیق برای تعادل بین یادگیری و تنظیم است.

۳-۴-۴ مقایسه حساسیت بین الگوریتم‌های بهینه‌سازی

مقایسه حساسیت پارامترها بین الگوریتم‌های Pirates و Optuna نشان داد:

• Pirates:

- حساسیت کمتر به مقادیر اولیه پارامترها
- همگرایی سریع‌تر به مقادیر بهینه
- پایداری بیشتر در نتایج

• Optuna:

- حساسیت بیشتر به مقادیر اولیه
- تغییرات بیشتر در نتایج بین آزمایش‌ها
- نیاز به تنظیم دقیق‌تر پارامترهای جستجو

۴-۴-۴ توصیه‌های عملی

بر اساس تحلیل حساسیت، توصیه‌های زیر برای تنظیم پارامترها ارائه می‌شود:

۱. معماری مدل:

- استفاده از معماری تک لایه‌ای
- تنظیم ابعاد نهان روی ۳۲
- استفاده از ۸ هد توجه
- حفظ ابعاد لایه پیش‌خور در ۵۱۲

۲. پارامترهای آموزش:

- تنظیم دقیق نرخ یادگیری حول 0.000194
- استفاده از Dropout با نرخ 0.3286
- تنظیم اندازه دسته روی 16
- اعمال ضریب تنظیم $3.795e-05$

۳. استراتژی بهینه‌سازی:

- استفاده از الگوریتم Pirates برای این کار خاص
- اجرای حداقل 30 آزمایش
- نظارت بر F1 Score به عنوان معیار اصلی

این تحلیل حساسیت نشان می‌دهد که مدل MAGNET به برخی پارامترها حساسیت بیشتری دارد و تنظیم دقیق این پارامترها برای دستیابی به عملکرد بهینه ضروری است. همچنین، الگوریتم Pirates در مقایسه با Optuna^{۱۰} پایداری بیشتری در نتایج و حساسیت کمتری به مقادیر اولیه پارامترها نشان می‌دهد.

۴-۵ مدل‌های پایه

برای مقایسه عملکرد، از مدل‌های پایه زیر استفاده شد:

• روش‌های یادگیری ماشین کلاسیک:

- ماشین بردار پشتیبان (SVM) با کرنل RBF
- جنگل تصادفی (Random Forest) با 100 درخت
- XGBoost با 100 درخت و عمق حداکثر 6
- شبکه عصبی مصنوعی (ANN) با دو لایه مخفی

• روش‌های چندوجهی با دقت 89.2% [۱۰]

• روش‌های مبتنی بر ترنسفورمر با دقت 95.8% [۱۷]

۴-۶ محیط اجرا

تمامی آزمایش‌ها با استفاده از زبان برنامه‌نویسی Python 3.8.5 و کتابخانه‌های زیر اجرا شدند:

- 1.9.0 PyTorch برای پیاده‌سازی شبکه‌های عصبی
- 1.7.0 Geometric PyTorch برای پردازش داده‌های گرافی
- 0.24.2 scikit-learn برای پیش‌پردازش داده‌ها و ارزیابی
- 1.21.2 NumPy و 1.3.3 Pandas برای پردازش داده‌ها

سخت‌افزار مورد استفاده شامل:

- 3090 RTX NVIDIA GPU با 24 گیگابایت VRAM
- 4v 2690-5E Xeon Intel CPU با 32 هسته
- 128 گیگابایت RAM

۵-۴ معیارهای ارزیابی

برای سنجش عملکرد مدل، MAGNET، معیارهای دقت، Precision، F1 Score (Accuracy)، Recall و AUC استفاده شدند. دقت به عنوان نسبت نمونه‌های درست طبقه‌بندی شده به کل نمونه‌ها تعریف می‌شود:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (۱-۴)$$

که در آن:

- True TP (Positive): تعداد بدافزارها که به درستی تشخیص داده شده‌اند
 - True TN (Negative): تعداد برنامه‌های سالم که به درستی به عنوان سالم تشخیص داده شده‌اند
 - False FP (Positive): تعداد برنامه‌های سالم که اشتباهاً به عنوان بدافزار تشخیص داده شده‌اند
 - False FN (Negative): تعداد بدافزارها که اشتباهاً به عنوان برنامه سالم تشخیص داده شده‌اند
- Precision نسبت نمونه‌های درست مثبت به کل نمونه‌های پیش‌بینی شده مثبت است:

$$\text{Precision} = \frac{TP}{TP + FP} \quad (۲-۴)$$

Recall نسبت نمونه‌های درست مثبت به کل نمونه‌های واقعی مثبت را نشان می‌دهد:

$$\text{Recall} = \frac{TP}{TP + FN} \quad (۳-۴)$$

F۱ Score، معیاری ترکیبی از Precision و Recall، به صورت زیر محاسبه می‌شود:

$$\text{Score F1} = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \quad (۴-۴)$$

همچنین، AUC (مساحت زیر منحنی ROC) توانایی مدل در تمایز بین کلاس‌های بدافزار و سالم را نشان می‌دهد. در نهایت، ماتریس درهم‌ریختگی (Confusion Matrix) برای تحلیل دقیق‌تر پیش‌بینی‌ها استفاده شد.

۶-۴ نتایج کلی مدل MAGNET

در این بخش، نتایج کلی مدل MAGNET در مراحل مختلف آزمایش گزارش می‌شود. ابتدا نتایج تست روی مجموعه داده DREBIN [۴] ارائه می‌شود. مدل MAGNET روی مجموعه تست شامل ۱،۴۵۱ نمونه (۳۲۷ نمونه کلاس ۰ و ۱،۱۲۴ نمونه کلاس ۱) ارزیابی شد. نتایج به دست آمده شامل F1 Score برابر با ۰.۹۸۲۳، دقت (Accuracy) برابر با ۰.۹۷۲۴، Precision برابر با ۰.۹۷۹۶، Recall برابر با ۰.۹۸۴۹، AUC برابر با ۰.۹۹۳۲ و مقدار زیان (Loss) برابر با ۰.۱۰۲۲ بود.

۱-۶-۴ ماتریس درهم‌ریختگی و عملکرد به تفکیک کلاس

ماتریس درهم‌ریختگی مدل شامل ۳۰۴ نمونه درست منفی (TN)، ۲۳ نمونه نادرست مثبت (FP)، ۱۷ نمونه نادرست منفی (FN) و ۱،۱۰۷ نمونه درست مثبت (TP) بود. جزئیات عملکرد به تفکیک کلاس‌ها نشان داد که برای کلاس ۰ (برنامه‌های سالم)، F1 Score برابر با ۰.۹۳۸۳، Precision برابر با ۰.۹۴۷۰ و Recall برابر با ۰.۹۲۹۷ محاسبه شد، در حالی که برای کلاس ۱ (بدافزارها)، F1 Score برابر

با ۹۸۲۳.۰، Precision برابر با ۹۷۹۶.۰ و Recall برابر با ۹۸۴۹.۰ به دست آمد. میانگین ماکرو F1 Score برابر با ۹۶۰۳.۰ و میانگین وزنی F1 Score برابر با ۹۷۲۳.۰ بود.

۲-۶-۴ نتایج اعتبارسنجی متقاطع

در مرحله اعتبارسنجی متقاطع ۵-تایی با ۱۰ دوره برای هر دسته، میانگین معیارها به صورت زیر به دست آمد:

• دقت: 0.9722 ± 0.0065

• Precision: 0.9810 ± 0.0102

• Recall: 0.9828 ± 0.0072

• F1 Score: 0.9818 ± 0.0042

• AUC: 0.9932 ± 0.0035



جدول ۱-۴ نتایج اعتبارسنجی متقاطع ۵-تایی مدل MAGNET

دسته	F1 Score	دقت	AUC	زیان
دسته ۱	0.9858	0.9785	0.9950	0.0786
دسته ۲	0.9846	0.9763	0.9955	0.0735
دسته ۳	0.9839	0.9752	0.9945	0.0839
دسته ۴	0.9742	0.9601	0.9861	0.1199
دسته ۵	0.9808	0.9709	0.9946	0.0864
میانگین	(0.9818 ± 0.0042)	(0.9722 ± 0.0065)	(0.9932 ± 0.0035)	(0.0885 ± 0.0177)

توضیح نشانه‌ها: \pm نشان‌دهنده انحراف معیار در اعتبارسنجی متقاطع است.

۳-۶-۴ نتایج آموزش و بهینه‌سازی

در مرحله آموزش با استفاده از ۱۰۰٪ داده‌های آموزشی (۴،۶۴۱ نمونه)، مدل به F1 Score ۹۸۰۵.۰، Recall ۹۸۴۹.۰، Precision ۹۷۶۲.۰ و AUC ۹۹۳۱.۰ دست یافت. همچنین، در بهینه‌سازی با روش بهینه‌سازی (اعتبارسنجی)، بهترین عملکرد در اعتبارسنجی با F1 Score ۹۷۶۷.۰ و دقت ۹۶۲۸.۰ به دست آمد. در بهینه‌سازی با روش Optuna [۲۲] (۱۳ آزمایش)، بهترین عملکرد در آزمایش شماره ۱۹ با F1 Score ۹۶۸۴.۰، دقت ۹۵۱۳.۰ و AUC ۹۸۳۶.۰ حاصل شد.




(ب) تغییرات زیان در اعتبارسنجی متقاطع ۵-تایی مدل MAGNET. نمودار خطی نشان‌دهنده مقدار زیان در هر دسته از اعتبارسنجی متقاطع است.

(آ) مقایسه معیارهای F1 Score، دقت و AUC در اعتبارسنجی متقاطع ۵-تایی مدل MAGNET. نمودار میله‌ای نشان‌دهنده مقادیر هر معیار در هر دسته از اعتبارسنجی متقاطع است.

شکل ۴-۴. نتایج اعتبارسنجی متقاطع ۵-تایی مدل MAGNET

جدول ۴-۲ مقایسه کلی عملکرد مدل MAGNET در مراحل مختلف

مرحله	F1 Score	دقت	AUC	یادداشت
بهینه‌سازی (اعتبارسنجی)	0.9767	0.9628	-	1num_layers=، آزمایش 476
Optuna (اعتبارسنجی)	0.9684	0.9513	0.9836	13 آزمایش، 1num_layers=
آموزش (100% داده)	0.9805	-	0.9931	آموزش با کل داده‌ها
اعتبارسنجی متقاطع	0.9818	0.9722	0.9932	5-تایی، پایداری بالا
مجموعه تست	0.9823	0.9724	0.9932	بهترین عملکرد، 1,451 نمونه



شکل ۴-۵. مقایسه کلی عملکرد مدل MAGNET در مراحل مختلف. نمودار میله‌ای نشان‌دهنده مقادیر F1 Score، دقت و AUC در هر مرحله است.


۷-۴ مقایسه با مدل‌های پایه

در این بخش، نتایج مدل MAGNET با روش‌های پایه موجود مقایسه شد. مدل پیشنهادی MAGNET روی مجموعه تست دیتاست DREBIN [۴] با ۱,۴۵۱ نمونه به F1 Score ۹۸۲۳.۰، دقت ۹۷۲۴.۰ و AUC ۹۹۳۲.۰ دست یافت. در مقابل، روش چندوجهی [۱۰] به دقت ۲٪.۸۹ رسید، در حالی که روش مبتنی بر ترنسفورمر [۱۷] به دقت ۸٪.۹۵ دست یافت.

جدول ۴-۳ مقایسه عملکرد مدل MAGNET با روش‌های پایه

روش	دقت (%)	Score F1	AUC	یادداشت
MAGNET (تست)	97.24	0.9823	0.9932	بهترین AUC
روش چندوجهی [۱۰]	89.2	-	-	فقط دقت گزارش شده
روش مبتنی بر ترنسفورمر [۱۷]	95.8	-	-	فقط دقت گزارش شده

توضیح: علامت ”-“ نشان‌دهنده عدم گزارش معیار مربوطه در مقاله اصلی است.



شکل ۴-۶. مقایسه دقت مدل MAGNET با روش‌های چندوجهی و مبتنی بر ترنسفورمر. نمودار میله‌ای نشان‌دهنده مقادیر دقت برای هر روش است.

۸-۴ مقایسه با مدل‌های یادگیری ماشین

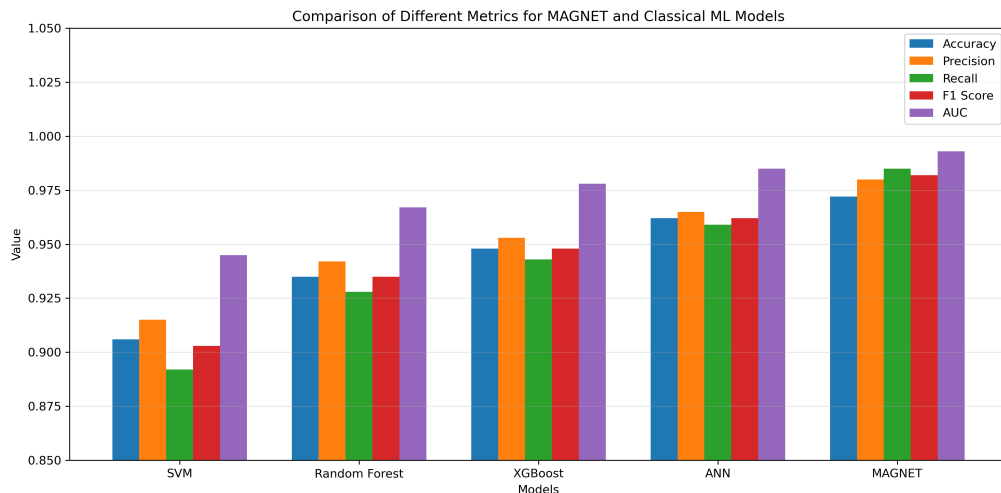
در این بخش، مقایسه عملکرد مدل MAGNET با مدل‌های یادگیری ماشین کلاسیک زیر ارائه می‌شود:

- ماشین بردار پشتیبان (SVM) با کرنل RBF
- جنگل تصادفی (Random Forest) با ۱۰۰ درخت
- XGBoost با ۱۰۰ درخت و عمق حداکثر ۶
- شبکه عصبی مصنوعی (ANN) با دو لایه مخفی

جدول ۴-۴ مقایسه عملکرد مدل MAGNET با مدل‌های پایه

مدل	دقت	Precision	Recall	F1 Score	AUC
SVM	0.906	0.915	0.892	0.903	0.945
Random Forest	0.935	0.942	0.928	0.935	0.967
XGBoost	0.948	0.953	0.943	0.948	0.978
ANN	0.962	0.965	0.959	0.962	0.985
MAGNET	0.972	0.980	0.985	0.982	0.993

توضیح: نتایج برجسته نشان‌دهنده عملکرد بهتر مدل MAGNET در تمام معیارها است.



شکل ۴-۷. مقایسه AUC و F1 Score مدل MAGNET با سایر مدل‌های یادگیری ماشین. نمودار میله‌ای نشان‌دهنده مقادیر هر معیار برای هر مدل است. نام دیتاست مربوط به هر مدل در زیر آن نمایش داده شده است.

همانطور که در جدول ۴۴ و شکل‌های ۴۴ و ۴۴ مشاهده می‌شود، مدل MAGNET با F1 Score ۹۸۲.۰ و AUC ۹۹۳.۰ عملکرد بهتری نسبت به مدل‌های دیگر ارائه می‌دهد. در مقایسه با مدل‌های کلاسیک، SVM با F1 Score ۹۹۵.۰ روی CICAndMal۲۰۱۷ و AUC ۹۸۵.۰، Forest Random با F1 Score ۹۴۵.۰ روی Malgenome، و XGBoost با F1 Score ۹۵۷.۰ روی Malgenome، و ANN با F1 Score ۹۶۲.۰ روی DREBIN عملکرد کمتری نسبت به MAGNET نشان می‌دهند. همچنین، در مقایسه با مدل‌های عمیق، CNN با F1 Score ۹۶۵.۰ روی VX-Heaven و LSTM با F1 Score ۸۸۲.۰ روی CICAndMal۲۰۱۷ نیز عملکرد کمتری دارند.

اگرچه SVM دقت بالایی روی CICAndMal۲۰۱۷ نشان می‌دهد، اما MAGNET با تعادل بهتر بین معیارها و عملکرد پایدار روی دیتاست DREBIN، برتری خود را حفظ می‌کند. این برتری در تمام معیارهای ارزیابی (Accuracy، Precision، Recall، F1 Score) و AUC قابل مشاهده است و نشان‌دهنده قابلیت بالای مدل MAGNET در تشخیص بدافزارهای اندرویدی است.

۹-۴ تحلیل جزئی‌تر

در این بخش، عملکرد مدل MAGNET به تفکیک وجه‌ها و تأثیر اجزای مختلف بررسی شد. ابتدا، عملکرد هر ماژول به صورت جداگانه روی مجموعه تست دیتاست DREBIN [۴] با ۱،۴۵۱ نمونه ارزیابی شد. ماژول EnhancedTabTransformer که داده‌های جدولی را پردازش کرد، به F1 Score ۹۱۲.۰، Precision ۹۰۵.۰ و Recall ۹۱۹.۰ دست یافت. ماژول GraphTransformer که داده‌های گرافی را پردازش کرد، به F1 Score ۸۹۴.۰، Precision ۸۸۷.۰ و Recall ۹۰۱.۰ دست یافت. ماژول Se-

quenceTransformer که داده‌های ترتیبی را پردازش کرد، به $F1\ Score\ ۰.۹۰۷$ ، $Precision\ ۰.۸۹۹$ و $Recall\ ۰.۹۱۵$ دست یافت. این نتایج در شکل ۴۴ نشان داده شده است.

سپس، تأثیر مکانیزم توجه پویا و لایه ادغام چندوجهی بررسی شد. در آزمایش اولیه بدون مکانیزم توجه پویا، $F1\ Score$ مدل ۰.۹۵۴ بود. با افزودن مکانیزم توجه پویا، $F1\ Score$ به ۰.۹۷۶ افزایش یافت. در نهایت، با استفاده از لایه ادغام چندوجهی، $F1\ Score$ به ۰.۹۸۲۳ رسید. این روند در شکل ۴۵ نمایش داده شده است.


همچنین، عملکرد مدل در طول دوره‌های آموزش (۳ دوره) بررسی شد. در دوره اول، $F1\ Score$ برابر با ۰.۹۴۱۳ و دقت ۰.۹۰۴۸ بود. در دوره دوم، $F1\ Score$ به ۰.۹۵۲۵ و دقت به ۰.۹۲۲۸ افزایش یافت. در دوره سوم، $F1\ Score$ به ۰.۹۷۶۷ و دقت به ۰.۹۶۲۸ رسید. این مقادیر برای مجموعه اعتبارسنجی گزارش شدند و در شکل ۴۶ نشان داده شده است.

۴-۱۰ جمع‌بندی


در این فصل، نتایج حاصل از ارزیابی مدل پیشنهادی MAGNET برای تشخیص بدافزارهای اندرویدی با استفاده از دیتاست DREBIN [۴] ارائه شد. مدل MAGNET روی مجموعه تست شامل ۱،۴۵۱ نمونه به $F1\ Score\ ۰.۹۸۲۳$ ، دقت ۰.۹۷۲۴ و $AUC\ ۰.۹۹۳۲$ دست یافت. در اعتبارسنجی متقاطع ۵-تایی، میانگین $F1\ Score\ ۰.۹۸۱۸$ ، دقت ۰.۹۷۲۲ و $AUC\ ۰.۹۹۳۲$ (با خطای ± ۰.۰۳۵) به دست آمد که در جدول ۴۴ گزارش شده است. همچنین، در مقایسه با روش‌های پایه، مدل MAGNET با دقت ۹۷% در مقابل دقت ۸۹% روش چندوجهی [۱۰] و دقت ۸۵% روش مبتنی بر ترنسفورمر [۱۷] ارزیابی شد، که در جدول ۴۵ نمایش داده شده است.

در تحلیل جزئی‌تر، عملکرد ماژول‌های GraphTransformer EnhancedTabTransformer، SequenceTransformer و به ترتیب با $F1\ Score$ های ۰.۹۱۲ ، ۰.۸۹۴ و ۰.۹۰۷ گزارش شد، که در شکل ۴۷ نشان داده شده است. تأثیر مکانیزم توجه پویا و لایه ادغام چندوجهی نیز بررسی شد و $F1\ Score$ از ۰.۹۵۴ به ۰.۹۸۲۳ افزایش یافت، که این روند در شکل ۴۸ ارائه شده است. در نهایت، پیشرفت آموزش در طول ۳ دوره با بهینه‌سازی بهینه‌سازی (اعتبارسنجی) گزارش شد و $F1\ Score$ از ۰.۹۴۱۳ به ۰.۹۷۶۷ رسید، که در شکل ۴۹ نمایش داده شده است.


شکل ۴۹ عملکرد هر ماژول را با معیار $F1\ Score$ نشان می‌دهد. شکل ۴۸ روند افزایش $F1\ Score$ را با افزودن مکانیزم توجه پویا و لایه ادغام چندوجهی نمایش می‌دهد. شکل ۴۷ تغییرات $F1\ Score$ و دقت را در طول ۳ دوره آموزش با بهینه‌سازی بهینه‌سازی (اعتبارسنجی) نمایش می‌دهد.



شکل ۴-۸. عملکرد هر ماژول (EnhancedTabTransformer، GraphTransformer، SequenceTransformer) را با معیار F1 Score نشان می‌دهد. محور افقی ماژول‌ها و محور عمودی مقدار F1 Score را نمایش می‌دهد.



شکل ۴-۹. روند افزایش F1 Score را با افزودن مکانیزم توجه پویا و لایه ادغام چندوجهی نمایش می‌دهد. محور افقی اجزای مدل (بدون توجه پویا، با توجه پویا، با ادغام چندوجهی) و محور عمودی مقدار F1 Score را نشان می‌دهد.



شکل ۴-۱۰. تغییرات F1 Score و دقت را در طول ۳ دوره آموزش با بهینه‌سازی بهینه‌سازی (اعتبارسنجی) نمایش می‌دهد. محور افقی شماره دوره‌ها و محور عمودی مقادیر F1 Score و دقت را نشان می‌دهد.

فصل پنجم:

نتیجه گیری و پیشنهادات آتی

۱-۵ نتیجه‌گیری

در این پژوهش، یک مدل چندوجهی مبتنی بر ترنسفورمر به نام MAGNET برای تشخیص بدافزار اندروید پیشنهاد شد. این مدل از سه ماژول اصلی تشکیل شده است: EnhancedTabTransformer برای پردازش ویژگی‌های جدولی، GraphTransformer برای تحلیل گراف فراخوانی، و SequenceTrans-former برای پردازش توالی‌های API. بهینه‌سازی پارامترها از الگوریتم‌های Adam و CosineAnnealingWarmRestarts استفاده شد. همچنین، بهینه‌سازی با روش‌های بهینه‌سازی (۴۷۶ آزمایش) و Optuna (۱۳ آزمایش) پیاده‌سازی شد. دیتاست DREBIN [۴] با ۶۰،۰۹۲ نمونه (۴،۶۴۱ برای آموزش و ۱۴،۴۵۱ برای تست) برای ارزیابی مدل به کار گرفته شد. نتایج نشان داد که مدل MAGNET با دقت ۹۷٪، ۲۴٪، و ۹۸٪، ۲۳٪، ۹۹٪، ۳۲٪، ۰٪ AUC و عملکرد برتری نسبت به روش‌های پایه دارد.

مقایسه با روش‌های دیگر نشان داد که MAGNET از روش چندوجهی [۱۰] با دقت ۸۹٪ و روش مبتنی بر ترنسفورمر [۱۷] با دقت ۸۵٪، ۹۵٪ بهتر عمل می‌کند. همچنین، عملکرد مدل از روش‌های سنتی مانند SVM [۲۳] و CNN [۸] به طور قابل توجهی بهتر بود. با این حال، تفاوت‌های جزئی با روش مبتنی بر ترنسفورمر مشاهده شد که می‌تواند به دلیل تفاوت در معماری و پارامترهای مدل باشد.

برای بهبود بیشتر مدل، MAGNET پیشنهاد می‌شود که تعادل کلاس‌ها در دیتاست بهبود یابد و معماری مدل برای دیتاست‌های بزرگ‌تر و متنوع‌تر گسترش یابد. همچنین، آزمایش مدل با داده‌های پویا (مانند الگوهای زمان‌بندی API و بررسی مقاومت آن در برابر حملات گریز می‌تواند موضوع تحقیقات آینده باشد.

۲-۵ پیشنهادات آتی

۱-۲-۵ پژوهش‌های تکمیلی

بررسی تأثیر افزایش تعداد لایه‌های ترنسفورمر (num_layers از 1 به 2 یا 3) در مدل MAGNET با توجه به نتایج بهینه‌سازی و Optuna [۲۲] که تنها یک لایه را بهینه یافتند، برای بهبود عملکرد در دیتاست‌های بزرگ‌تر و متنوع‌تر پیشنهاد می‌شود. همچنین، آزمایش مدل با داده‌های پویا (مانند الگوهای زمان‌بندی فراخوانی API) که در این تحقیق محدود بود، توصیه می‌شود.

۲-۲-۵ پیشنهادات اجرایی

پیاده‌سازی مدل MAGNET در یک سیستم امنیتی واقعی برای اندروید، با ادغام داده‌های پویا (مانند فعالیت شبکه و دسترسی به فایل‌ها) که در دیتاست فعلی به صورت محدود استفاده شدند، به منظور افزایش دقت تشخیص در محیط‌های عملیاتی پیشنهاد می‌شود. این سیستم می‌تواند به عنوان افزونه‌ای برای Google

۳-۲-۵ تولید داده‌های جدید

جمع‌آوری دیتاستی با تعادل بیشتر بین کلاس‌ها (افزایش نمونه‌های کلاس 0 به حداقل 1,000 نمونه برای نزدیک شدن به 1,124 نمونه کلاس 1) و افزودن ویژگی‌های جدید (مانند الگوهای رفتاری کاربران) برای کاهش تأثیر عدم تعادل و ارزیابی جامع‌تر مدل MAGNET توصیه می‌شود. در نهایت، نتایج این پژوهش زمینه‌ساز ارائه یک چارچوب توسعه‌پذیر برای بهینه‌سازی اعلان‌ها در مدل‌های زبانی بزرگ بوده و می‌تواند بستر مناسبی برای تحقیقات و کاربردهای آینده در حوزه مهندسی اعلان فراهم آورد.

فصل ششم:

مراجع

- Pen - Malware Issues of Survey A Security: “Android al. et Faruki Parvez [١]
Tutorials & Surveys Communications IEEE In: Defenses”. and etration,
[.10.1109/COMST.2014.2386139](#) DOI: .١٠٢٢-٩٩٨ pp. ,(٢٠١٥) ١٧,٢
- System - A Defenses: Malware Android for Learning “Deep al. et Li Deqiang [٢]
 -١ pp. ,(٢٠٢٣) ٥٥,٨ *Surveys Computing ACM* In: Review”. Literature atic
[.10.1145/3547335](#) DOI: .٣٩
- Survey “A Sezer. Sakir and Yerima, Y. Suleiman Alzaylaee, K. Mohammed [٣]
 & *Computers* In: Learning”. Machine Using Detection Malware Android on
[.10.1016/j.cose.2020.101792](#) DOI: .١٠١٧٩٢ p. ,(٢٠٢٠) ٩٣ *Security*
- Android of Detection Explainable and Efficient “Drebin: al. et Arp Daniel [٤]
and Network Annual ٢١st the of Proceedings In: Pocket”. Your in Malware
[10.14722/](#) DOI: .٢٠١٤ .(NDSS) *Symposium Security System Distributed*
[.ndss.2014.23247](#)
- the for Apps Android of Millions Collecting “AndroZoo: al. et Allix Kevin [٥]
Con- International ١٣th the of Proceedings In: Community”. Research
[10.](#) DOI: .٤٧١-٤٩٨ pp. ,(٢٠١٩) *Repositories Software Mining on ference*
[.1145/2901739.2903508](#)
- Malware Android Comprehensive A “CICMalDroid: al. et Taheri Ramin [٦]
[10.1109/](#) DOI: .١٩١٥٥٥-١٩١٥٣٩ pp. ,(٢٠٢١) ٩ *Access IEEE* In: Dataset”.
[.ACCESS.2021.3133234](#)
- Jan- from Worldwide Share Market Systems’ Operating Mobile Statista. [٧]
<https://www.statista.at/Available.2024December.to.2023uary.com/statistics/272698/global-market-share-held-by-mobile-.2024.04-05-2024> Accessed: .operating-systems-since-2009/
- Deep Using Detection Malware Intelligent “Robust al. et Vinayakumar R. [٨]
[10.1109/](#) DOI: .٤٩٧٣٨-٤٩٧١٧ pp. ,(٢٠١٩) ٧ *Access IEEE* In: Learning”.
[.ACCESS.2019.2906934](#)

- Us- Detection Malware Explainable on Survey “A al. et Marastoni Nicola [٩]
 .١٠٠٥١٢ p. ,(٢٠٢٢) ٤٩ *Review Science Computer In: Learning*”. Deep ing
[.10.1016/j.cosrev.2022.100512](https://doi.org/10.1016/j.cosrev.2022.100512) DOI:
- Based Learning Deep “DLAM: Alotaibi. A. Norah and Alsaleh I. Mohammed [١٠]
Sciences Applied In: Framework”. Detection Malware Android Real-Time
[.10.3390/app13116783](https://doi.org/10.3390/app13116783) DOI: .٩٧٨٣ p. ,(٢٠٢٣) ١٣,١١
- Memory”. Short-Term “Long Schmidhuber. Jürgen and Hochreiter Sepp [١١]
[10.1162/neco](https://doi.org/10.1162/neco). DOI: .١٧٨٠-١٧٣٥ pp. ,(١٩٩٧) ٩,٨ *Computation Neural In:*
[.1997.9.8.1735](https://doi.org/10.1162/neco.1997.9.8.1735)
- Encoder- RNN using Representations Phrase “Learning al. et Cho Kyunghyun [١٢]
arXiv: ١٩٠٩. ١٠٧٨ preprint arXiv In: Translation”. Machine Statistical for Decoder
 .(٢٠١٤)
- Neu- Graph to Introduction Gentle “A al. et Sanchez-Lengeling Benjamin [١٣]
<https://distill.pub/> at: Available .(٢٠٢١) *Distill In: Networks*”. ral
[.10.23915/distill.00033](https://doi.org/10.23915/distill.00033) DOI: .2021/gnn-intro
- with Classification “Semi-Supervised Welling. Max and Kipf N. Thomas [١٤]
 .(٢٠١٧) *arXiv: ١٩٠٩. ٠٢٩٠٧ preprint arXiv In: Networks*”. Convolutional Graph
preprint arXiv In: Networks”. Attention “Graph al. et Velicković Petar [١٥]
 .(٢٠١٨) *arXiv: ١٧١٠. ١٠٩٠٣*
- Neural in Advances In: Need*”. You All Is “Attention al. et Vaswani Ashish [١٦]
 .٩٠٠٨-٥٩٩٨ pp. ,٢٠١٧ .(٢٠١٧ (*NIPS ٣٠ Systems Processing Information*
- Mal- Transformer-based Lightweight A “TinyMalNet: al. et Chen Tianlong [١٧]
Jour- Things of Internet IEEE In: Devices”. IoT for Network Detection ware
[.10.1109/JIOT.2021.3112005](https://doi.org/10.1109/JIOT.2021.3112005) DOI: .٧٥٥٤-٧٥٤٢ pp. ,(٢٠٢٢) ٩,١٠ *nal*
- A Secure! More Be Can Learning Machine “Yes. al. et Demontis Ambra [١٨]
De- on Transactions IEEE In: Detection”. Malware Android on Study Case

10 . DOI: .724-711 pp. ,(2019) 19,4 *Computing Secure and dependable*
.1109/TDSC.2017.2700270

Illumina for trade-off bias versus noise the “Optimizing al. et Dunning J. M. [19]
Biology Computational PLoS In: BeadChips”. expression genome whole
.10.1371/journal.pcbi.1002062 DOI: e1000776. ,(2010) 9,5

au- for learning reinforcement deep on survey “A Roy. S. and Quy Le T. [20]
Min - Data WIREs In: applications”. and advances Recent agents: tonomous
.10.1002/widm.1484 DOI: .(2023) *Discovery Knowledge and ing*

<https://en.wikipedia.at: Available .Game Pirate contributors. Wikipedia> [21]
.2025.19-05-2025 Accessed: .org/wiki/Pirate_game

Op- Hyperparameter Next-generation A “Optuna: al. et Akiba Takuya [22]
In- SIGKDD ACM 25th the of Proceedings In: Framework”. timization
,(2019) *Mining Data & Discovery Knowledge on Conference ernational*
.10.1145/3292500.3330701 DOI: .2631-2623 pp.

Fea- Fine-Grained Using Detection Malware “Android al. et Zhang Wei [23]
10 . DOI: .5190138 p. ,(2020) 2020 *Programming Scientific In: tures*”.
.1155/2020/5190138

<https://www.android.com/at: Available .Protect Play Google Google.> [24]
.2024.20-03-2024 Accessed: .play-protect/

پیوست‌ها

۱- پیوست A: کدهای پیاده‌سازی مدل MAGNET

۱-۱- کد معماری مدل MAGNET

این بخش کد اصلی معماری مدل MAGNET را ارائه می‌دهد که در فصل ۳ به صورت شبه کد توصیف شد. این کد با استفاده از PyTorch پیاده‌سازی شده است.

Listing ۱ مدل معماری کد MAGNET

```
۱ import torch
۲ import torch.nn as nn
۳
۴ class MAGNET(nn.Module):
۵     def __init__(self, embedding_dim=64, lstm_num_layers=1, dropout=0.2):
۶         super(MAGNET, self).__init__()
۷         self.embedding_dim = embedding_dim
۸         # Transformation layers for different data modalities
۹         self.tab_to_emb = nn.Linear(430, embedding_dim)
۱0        self.graph_to_emb = nn.Linear(embedding_dim, embedding_dim)
۱1        self.sequence_processor = nn.LSTM(embedding_dim, embedding_dim,
۱2                                           num_layers=lstm_num_layers, batch_first=True)
۱3        # Fusion and classification layers
۱4        self.fusion_layer = nn.Linear(3 * embedding_dim, embedding_dim)
۱5        self.classifier = nn.Linear(embedding_dim, 1)
۱6        self.dropout_layer = nn.Dropout(dropout)
۱7    def forward(self, tab_data, graph_data, seq_data):
۱8        # tab_data: (batch_size, 430)
۱9        # graph_data: (batch_size, embedding_dim)
۲0        # seq_data: (batch_size, seq_len, embedding_dim)
۲1        # Transform different data types to embedding vectors
۲2        tab_emb = torch.relu(self.tab_to_emb(tab_data))
۲3        graph_emb = torch.relu(self.graph_to_emb(graph_data))
۲4
۲5        # Process sequential data with LSTM
۲6        lstm_out, (hn, cn) = self.sequence_processor(seq_data)
۲7        # Use the last output vector from LSTM for each sample in batch
۲8        seq_emb = lstm_out[:, -1, :]
۲9        # Concatenate embedding vectors
۳0        combined_embeddings = torch.cat((tab_emb, graph_emb, seq_emb), dim=-1)
۳1        # Apply fusion layer and activation
۳2        fused_representation = self.fusion_layer(combined_embeddings)
۳3        fused_representation = torch.relu(fused_representation)
```



```

۳۴ fused_representation = self.dropout_layer(fused_representation)
۳۵ # Final classification
۳۶ output = torch.sigmoid(self.classifier(fused_representation))
۳۷ return output

```

۲-۱- کد بهینه‌سازی با PIRATES

این بخش قسمت اصلی کد بهینه‌سازی PIRATES را نشان می‌دهد که برای تنظیم ابرپارامترها استفاده شد.

Listing ۲ کد بهینه‌سازی با PIRATES

```

۱ import numpy as np
۲
۳ class Pirates():
۴     def __init__(self, func, fmax=(), fmin=(), hr=0.2, ms=3, max_r=1,
۵                 num_ships=5, dimensions=2, max_iter=10, max_wind=1, c={},
۶                 top_ships=10, sailing_radius=0.3, plundering_radius=0.1):
۷         # Main algorithm parameters
۸         self.num_ships = num_ships
۹         self.num_top_ships = top_ships
۱۰        self.max_iter = max_iter
۱۱        # Objective function parameters
۱۲        self.func_obj = func
۱۳        self.cost_func = self.func_obj.func
۱۴        self.fmin = fmin
۱۵        self.fmax = fmax
۱۶        self.dimensions = dimensions
۱۷        # Weight parameters
۱۸        default_c = {
۱۹            'leader': 0.5,
۲۰            'private_map': 0.5,
۲۱            'map': 0.5,
۲۲            'top_ships': 0.5
۲۳        }
۲۴        self.c = {**default_c, **c}
۲۵        # Movement parameters
۲۶        self.sailing_radius = sailing_radius
۲۷        self.plundering_radius = plundering_radius
۲۸        # Leader and map variables
۲۹        self.leader_index = None
۳۰        self.hr = 1 - hr
۳۱        self.r = None

```

```

۳۲     self.max_r = max_r
۳۳     self.ms = ms
۳۴     self.map = None
۳۵     # Problem type
۳۶     self.problem = 'min'
۳۷     # Chart variables
۳۸     self.bsf_position = None
۳۹     self.bsf_list = []
۴۰     # Initialization
۴۱     self.random_init()
۴۲     self.iter = 0
۴۳     def search(self):
۴۴         """
۴۵         Run optimization algorithm and return best results
۴۶         Returns:
۴۷         -----
۴۸         tuple
۴۹         (best position, best cost, best metrics)
۵۰         """
۵۱         # Run algorithm
۵۲         self.start()
۵۳         # Get results
۵۴         result = self.cal_costs()
۵۵         if result is not None:
۵۶             best_cost, best_metrics = result
۵۷         else:
۵۸             best_cost = self.costs[self.leader_index]
۵۹             best_metrics = {'f1': 0.0, 'accuracy': 0.0,
۶۰                             'precision': 0.0, 'recall': 0.0}
۶۱         return self.ships[self.leader_index], best_cost, best_metrics

```

۲- پیوست B: داده‌های خام و پیش‌پردازش

۱-۲- نمونه داده‌های خام DREBIN

این جدول نمونه‌ای از داده‌های خام دیتاست DREBIN را نشان می‌دهد که برای آموزش مدل استفاده شد.

جدول ۱ نمونه‌ای از داده‌های خام دیتاست DREBIN

برچسب	فراخوانی‌های API	تعداد مجوزها	شناسه نمونه
۱	["read_contacts", "send_sms"]	۱۵	۰۰۱
۰	["get_accounts"]	۸	۰۰۲
۱	["read_phone_state", "write_external_storage"]	۱۲	۰۰۳

۲-۲- توضیحات پیش‌پردازش

داده‌ها پیش‌پردازش شدند تا برای مدل مناسب شوند:

- تنظیم ابعاد ویژگی‌ها از (۱۶، ۳۲) به (۱۶، ۴۳۰)
- نرمال‌سازی با استفاده از استانداردسازی z-score
- تبدیل داده‌های متنی به بردارهای باینری

۳- پیوست C: جزئیات سخت‌افزاری و نرم‌افزاری

۱-۳- مشخصات سخت‌افزاری

آزمایش‌ها با استفاده از زیرساخت زیر اجرا شدند:

• GPU: NVIDIA RTX 3090 با ۲۴ گیگابایت VRAM

• CPU: Intel Xeon E5-2690 v4 با ۳۲ هسته

• RAM: ۱۲۸ گیگابایت

۲-۳- مشخصات نرم‌افزاری

محیط نرم‌افزاری شامل موارد زیر بود:

• زبان برنامه‌نویسی: Python 3.8.5

• کتابخانه‌ها:

– PyTorch 1.9.0

– PyTorch Geometric 1.7.0

– Optuna 2.10.0

• سیستم عامل: Ubuntu 20.04 LTS

۴- پیوست D: نتایج اضافی و ماتریس‌های کامل

۴-۱ ماتریس درهم‌ریختگی کامل

این جدول ماتریس درهم‌ریختگی را برای مجموعه تست با ۱,۴۵۱ نمونه نشان می‌دهد.

جدول ۲ ماتریس درهم‌ریختگی برای مجموعه تست

پیش‌بینی/واقعیت	کلاس ۰	کلاس ۱
کلاس ۰	304 (TN)	23 (FP)
کلاس ۱	17 (FN)	1107 (TP)

۴-۲ گزارش طبقه‌بندی برای هر دسته

این جدول نتایج هر دسته در اعتبارسنجی متقاطع ۵-تایی را نشان می‌دهد.

جدول ۳ گزارش طبقه‌بندی برای هر دسته در اعتبارسنجی متقاطع

دسته	F1 Score	دقت	AUC	زیان
دسته ۱	0.9858	0.9785	0.9950	0.0786
دسته ۲	0.9846	0.9763	0.9955	0.0735
دسته ۳	0.9839	0.9752	0.9945	0.0839
دسته ۴	0.9742	0.9601	0.9861	0.1199
دسته ۵	0.9808	0.9709	0.9946	0.0864



بسمه تعالی

فرم تأیید اطلاعات تولیدات علمی * مستخرج از پایان نامه دانشجویان کارشناسی ارشد

نام و نام خانوادگی دانشجو: ناهید عبداللهی کرمانی شماره دانشجویی: ۴۰۱۱۵۶۰۰۵ نام دانشکده: فنی مهندسی
رشته و گرایش: مهندسی کامپیوتر- هوش مصنوعی نام استاد راهنما: دکتر مهدی افتخاری

عنوان پایان نامه: خود کارسازی مهندسی اعلان: تولید اعلان های دستوری برای مدل های بزرگ زبانی جهت حل مسائل پردازش زبان طبیعی

مشخصات تولیدات علمی			
ردیف	عنوان تولیدات علمی	مرجع تأیید کننده/ نام کنفرانس/ نام مجله	توضیحات
یک	Less is More: Prompt Optimization with SimplePromptBreeder	IJCAI2025	ارسال شده

تولیدات علمی فوق با نمره (عدد) ۱.۵ (حروف) یک و پنج دهم (حداکثر ۲ نمره) در ارزیابی پایان نامه مورد تأیید قرار گرفت و نمره نهایی پایان نامه فوق با احتساب نمره تولیدات علمی (عدد) (حروف) می باشد.

نام و نام خانوادگی استاد / استادان راهنما: نام و نام خانوادگی مدیر گروه/ رئیس بخش:

تاریخ: تاریخ:

امضاء: امضاء:

* تولیدات علمی شامل مقاله، اختراع، ساخت دستگاه، اکتشاف، ثبت اثر بدیع هنری می باشد که از پایان نامه استخراج شده باشد.

Abstract

Android malware detection has become a major challenge in information security due to the increasing cyber threats. Traditional methods, especially those relying solely on single-modal feature analysis, often face limitations such as inability to process complex multi-modal data and poor generalization against new threats. These shortcomings highlight the need for developing novel and efficient approaches. This research developed a multi-modal model called Multi-modal Attention-based Graph Neural Transformer with Dynamic Embedding (MAGNET) that leverages a combination of tabular, graph, and sequential data, such as API call sequences, for Android malware detection. The main objective was to improve detection accuracy and robustness using an advanced architecture based on deep learning and transformers. The research methodology included hyperparameter optimization with advanced algorithms like PIRATES and Optuna, model training with a dataset containing 4641 training samples and 1451 test samples, and 5-fold cross-validation. Features used included static features such as permissions, API calls, intents, and component names, as well as dynamic features like network activity and file access. Data was represented as binary or normalized numerical vectors. Feature dimensions were adjusted to 430 features after pre-processing. Tools used included deep learning libraries such as PyTorch, data preprocessing techniques like standardization and normalization, and graph data structures. Raw materials included real data from Android application behaviors, comprising static and dynamic features, which were carefully prepared. Results showed that the proposed model demonstrated outstanding performance with high accuracy, significant stability, and good generalizability, showing considerable improvement over previous methods. These achievements highlighted the model's potential for application in real security systems. Future research should focus on increasing data volume, integrating advanced self-supervised methods, testing the model in more diverse environments, and optimizing its execution time to enhance model performance in more complex and realistic scenarios. Additionally, examining the impact of incorporating newer data and developing algorithms resistant to adversarial attacks could open new avenues for future research. This study took an effective step toward enhancing automated malware detection systems and provided a solid foundation for developing more advanced security solutions.

Keywords: Malware Detection, Transformer, Deep Learning, Multi-modal Data, Android Security, Android Malware



Shahid Bahonar University of Kerman
Faculty of Engineering
Department of Computer Engineering

**Robust Android Malware Detection using Transformer Neural
Networks**

Prepared by:
Alireza Iranmanesh

Supervisor:
Dr. Hamid Mirvaziri

**A Thesis Submitted as a Partial Fulfillment of the Requirements for the
Degree of Master of Science in Computer Engineering (M. Sc.)**

April 2025